

UDEC
UNIVERSIDAD DE
CUNDINAMARCA

Etapa 6 Conocimiento Oculto

Angelica Rosa Olier Quiroga

Johan Orlando Martinez Suarez

Programa de Ingeniería de Sistemas y Computación

Universidad de Cundinamarca

Minería de Datos

Ingeniero Edison Gustavo Cañón Varela

Noviembre 2026

1. Contexto, objetivo y preguntas de análisis

El proyecto estudia la adopción de vehículos eléctricos e híbridos en Colombia con datos abiertos del Registro Único Nacional de Tránsito (RUNT 2.0, datos.gov.co ntxy-q9ix). Las etapas anteriores describieron el conjunto de datos (calidad, ETL, tableros de Power BI y modelo multidimensional). Esta etapa busca conocimiento oculto: patrones que no se ven en los análisis descriptivos, mediante aprendizaje supervisado, aprendizaje no supervisado y el análisis de comentarios de YouTube, todo con Orange Data Mining 3.40.

Objetivo. Descubrir patrones, relaciones y comportamientos que profundicen la comprensión del problema, y contrastarlos con las opiniones de usuarios para sustentar conclusiones y señalar qué decisiones podrían apoyarse en ellas.

Análisis	Pregunta	Técnica
Supervisado	Dados la clase, la carrocería, el departamento, el año de registro y el año del modelo de un grupo de vehículos, ¿son eléctricos o híbridos?	Clasificación binaria: regresión logística, árbol de decisión y Random Forest
No supervisado	¿Existen perfiles de territorio según la composición de clases de vehículo, la antigüedad del parque y su tamaño?	k-Means con normalización; silueta para elegir k
Texto	¿Qué barreras y motivaciones expresan los usuarios en YouTube y cómo complementan o cuestionan lo que muestra el RUNT?	Preprocesamiento en español, TF-IDF, LDA, bigramas y categorías

2. Datos y transformaciones

Fuente. Vehículos eléctricos e híbridos matriculados en Colombia (datos.gov.co, ntxy-q9ix), descargado el 14 de octubre de 2026. El conjunto es agregado: cada fila es un grupo de vehículos con las mismas características y la columna cantidad dice cuántos son. Por eso los vehículos se

cuentan con SUM(cantidad), nunca con el número de filas, y no son vehículos únicos ni parque activo (no hay placa), sino matrículas por año de registro.

Ventana y tratamiento previo. El análisis cubre 2015–2024: 6.772 grupos que suman 155.777 vehículos. Quedan fuera 2025–2026 (3.976 grupos y 177.124 vehículos; 2026 es un año incompleto). Se aplicó el tratamiento de calidad de la Etapa 2 (sin duplicados, carrocería nula como «SIN DATO», texto canónico y marcas que no eliminan filas: 34 grupos con modelo inusual y 942 grupos grandes, con más de 16 vehículos, que concentran el 88,35 % de los vehículos). Esos datos viven en el modelo en estrella (tabla de hechos y dimensión de territorios).

Transformaciones adicionales de la Etapa 6 (todas hechas con widgets de Orange):

Análisis	Transformación
Supervisado	Unir el departamento desde la dimensión de territorios; excluir hidrógeno (4 grupos, 4 vehículos: no son ni eléctricos ni híbridos y no hay ejemplos); crear antiguedad_modelo = año de registro − año del modelo y la clase tipo_motorizacion (ELÉCTRICO; HÍBRIDO = gasolina-eléctrico + diésel-eléctrico). Resultado: 6.768 grupos y 155.773 vehículos. cantidad queda como peso (meta), nunca como predictora; el combustible original se ignora para evitar fuga de información. Las variables numéricas se estandarizan en el flujo.
Clustering	Agregar por territorio con sumas ponderadas por cantidad; calcular 8 variables (log10 de vehículos, % camioneta, % automóvil, % campero, % micromovilidad, % registrado en 2022–2024, año de registro medio y antigüedad media); conservar los territorios con 30 o más vehículos (98 de 247, que reúnen el 99,19 % de los vehículos). No se usan el combustible ni la variable objetivo. Las variables se normalizan ($\mu = 0$, $\sigma = 1$) porque están en escalas muy distintas.

Análisis	Transformación
Comentarios	Extracción con la API de YouTube, limpieza (vacíos, publicidad, textos muy cortos, duplicados, otro idioma), anonimización y preprocesamiento en español (sección 6).

Los flujos de Orange parten de los CSV del modelo en estrella y reproducen estas transformaciones sin escribir código; un script en Python los replica solo para auditar las cifras.

3. Flujos de Orange Data Mining: configuración y comprobación

Se construyeron en Orange Data Mining 3.40 (con el complemento Text) los tres flujos de la Etapa 6. La mayoría de las cifras coincide con las de los scripts del repositorio (archivos resultados_etapa6_*.json): la regresión logística logra AUC 0,941 y accuracy 0,870; el clustering forma 3 grupos de 22, 34 y 42 territorios, y el corpus de comentarios deja un vocabulario de 1.690 términos.

Los flujos se guardaron en una carpeta local (fuera del repositorio) como 01_supervisado.ows, 02_clustering.ows y 03_comentarios_youtube.ows. Cada apartado describe la configuración de cada widget y muestra su captura de pantalla.

Flujo	Archivo	Pregunta
1 · Supervisado	01_supervisado.ows	¿Un grupo de vehículos es eléctrico o híbrido?
2 · Clustering	02_clustering.ows	¿Qué perfiles de territorio existen?
3 · Comentarios	03_comentarios_youtube.ows	¿De qué hablan los comentarios de YouTube?

El dataset es agregado: cada fila es un grupo de vehículos y la columna cantidad indica cuántos son. Por eso cantidad se usa como peso (meta) y nunca como predictora.

Flujo 1 - Supervisado: preparación de datos

La preparación deja 6.768 grupos de vehículos con 6 predictoras, la clase tipo_motorizacion y cantidad como peso. La Figura 1 muestra el flujo completo.

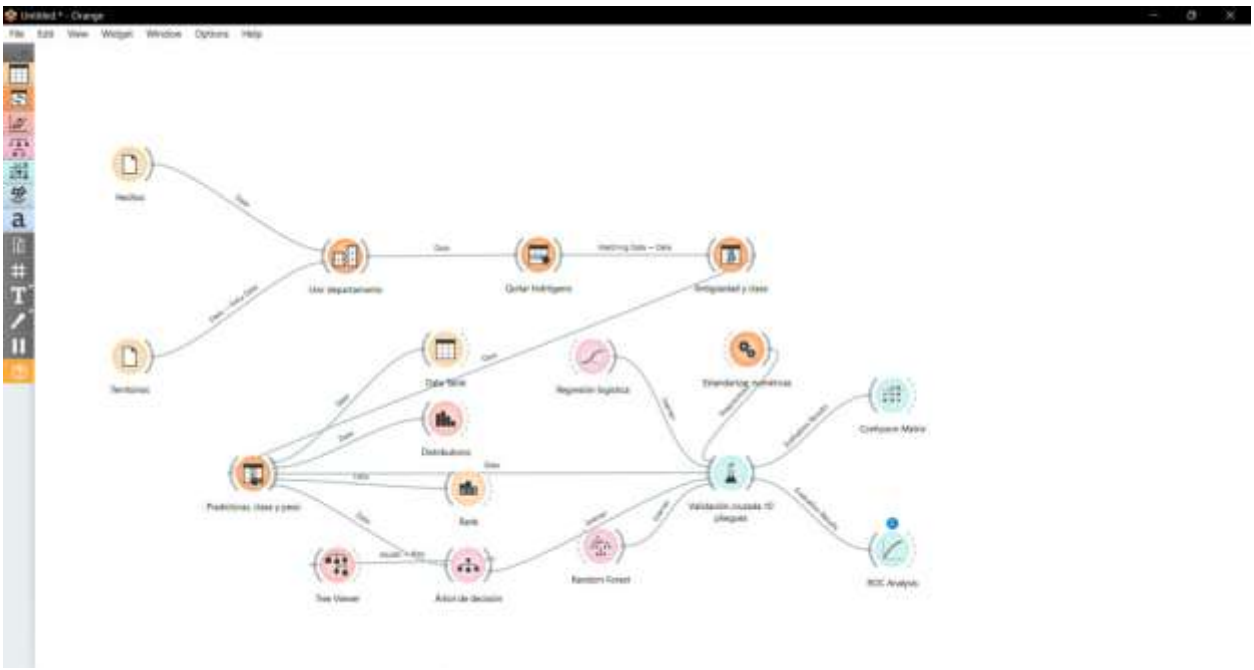


Figura 1. Lienzo del flujo 01_supervisado.ows.

File «Hechos». Carga data\powerbi\hechos_vehiculos.csv: 6.772 filas, 8 variables y territorio como meta de texto



Figura 2. Widget File “Hechos”

File «Territorios». Carga data\powerbi\dim_territorio.csv: 247 filas, departamento categórico y territorio y municipio como metas.

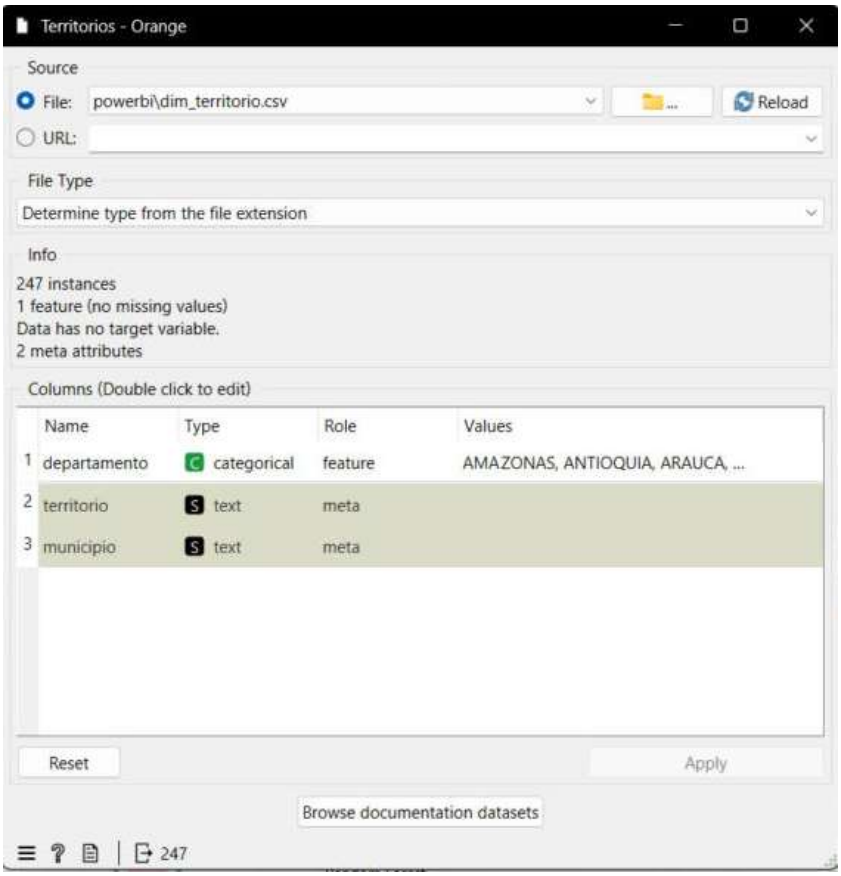


Figura 3. Widget File «Territorios».

Merge Data «Unir departamento». Modo «Append columns from Extra data», uniendo territorio = territorio. Salida: 6.772 filas con departamento.

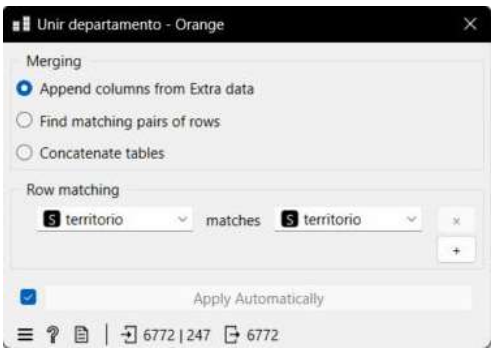


Figura 4. Widget Merge Data.

Select Rows «Quitar hidrógeno». Condición combustible is not HIDROGENO. Salida «Matching Data»: 6.768 filas (salen 4 grupos).

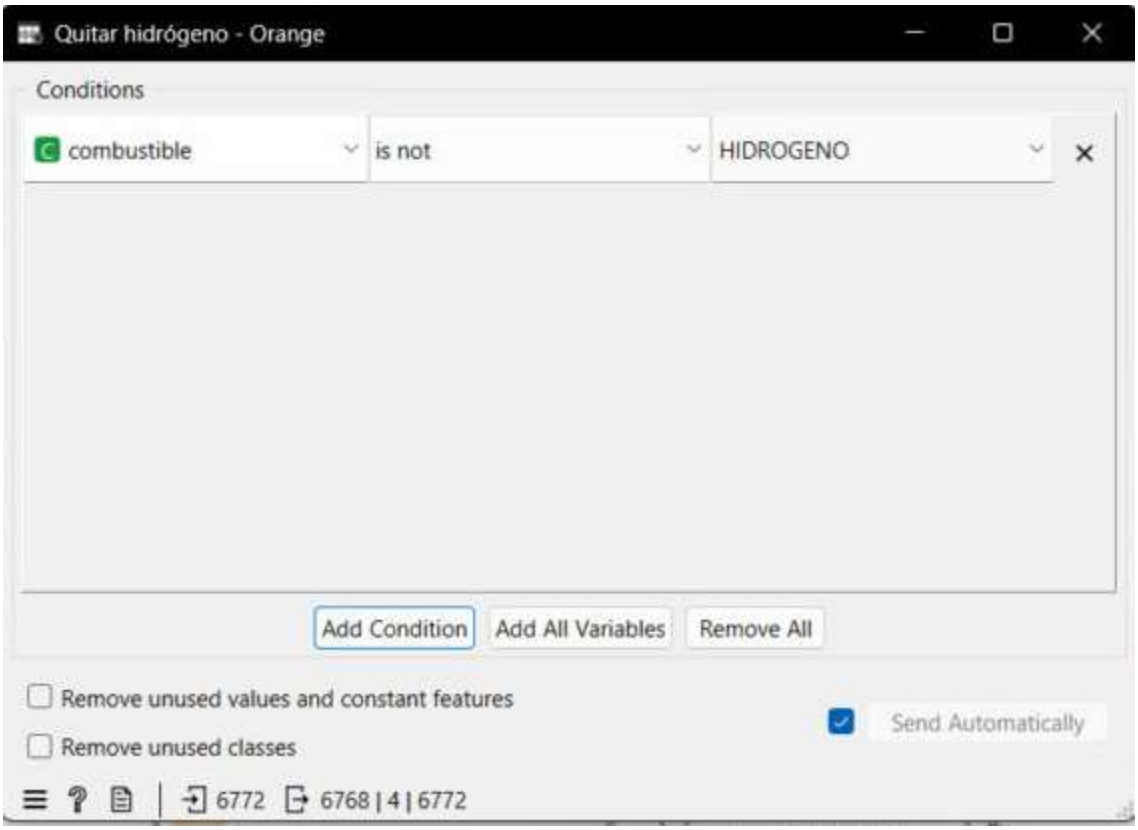


Figura 5. Widget Select Rows.

Formula «Antigüedad y clase». Crea dos variables:

• antiguedad_modelo (numérica) = anio_registro - modelo.

• tipo_motorizacion (categórica, valores ELECTRICO, HIBRIDO) = 0 if combustible == 'ELECTRICO' else 1.

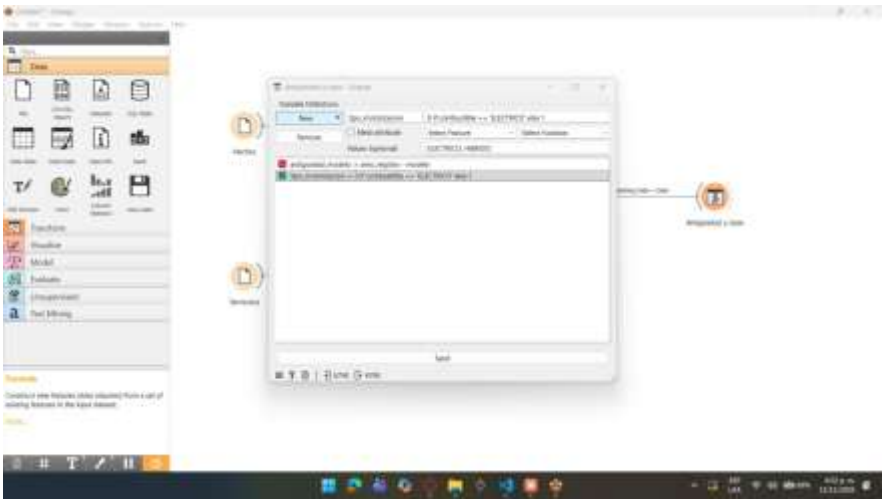


Figura 6. Widget Formula con las dos variables nuevas.

Select Columns «Predictoras, clase y peso». Features: clase, carroceria, departamento, anio_registro, modelo, antiguedad_modelo. Target: tipo_motorizacion. Meta: cantidad. Ignoradas: combustible (evita fuga de información), modelo_inusual, grupo_grande, territorio y municipio.

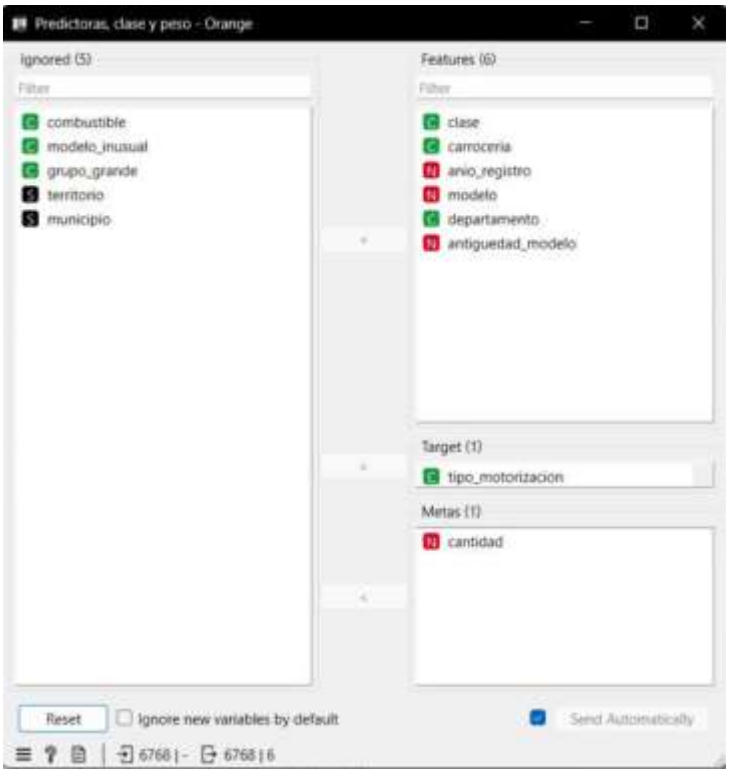


Figura 7. Widget Select Columns.

Flujo 1 - Modelos y evaluación

La regresión logística es el mejor modelo (AUC 0,941; CA 0,870), por delante de Random Forest (0,933) y el árbol (0,904). Los tres se evalúan con las mismas condiciones: validación cruzada estratificada de 10 pliegues y clase objetivo ELECTRICO.

Exploración. Distributions sobre tipo_motorizacion muestra 3.583 grupos ELECTRICO (52,9 %) y 3.185 HIBRIDO. Rank (ganancia de información) ubica carroceria (0,554) y clase (0,468) arriba; el resto queda por debajo de 0,07.



Figura 8. Distributions de tipo_motorizacion.

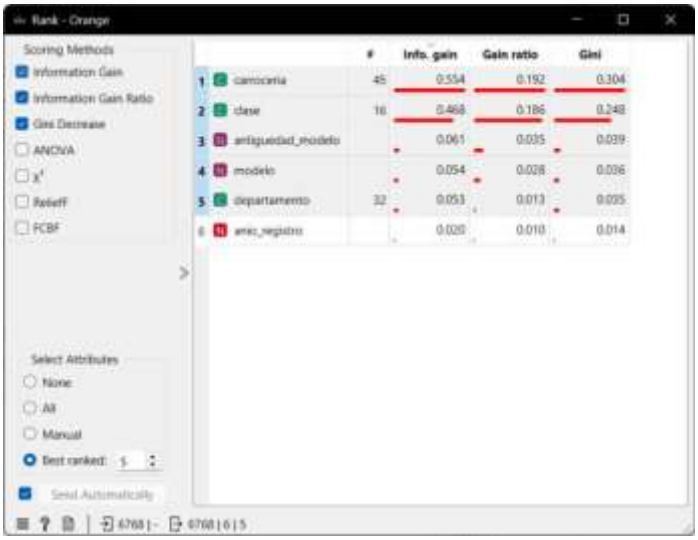


Figura 9. Rank de variables.

Preprocess «Estandarizar numéricas». Un solo paso: Normalize Features → Standardize to μ=0, σ^2=1. Su salida «Preprocessor» entra en Test and Score.

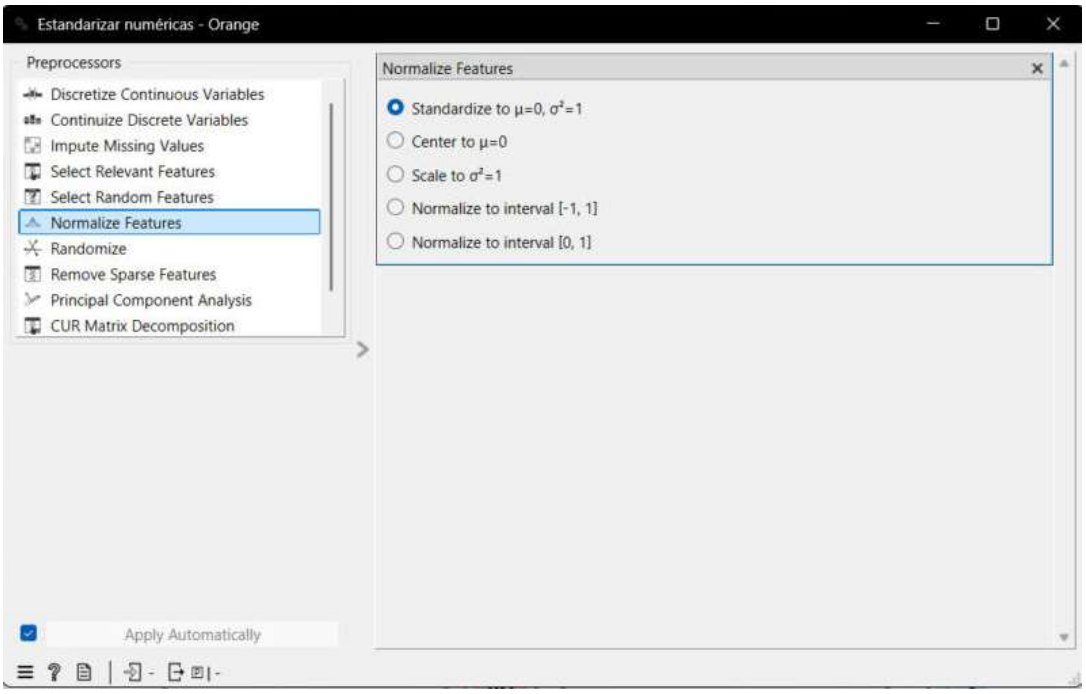


Figura 10. Widget Preprocess.

Logistic Regression. Regularización Ridge (L2), C = 1, sin balanceo de clases.

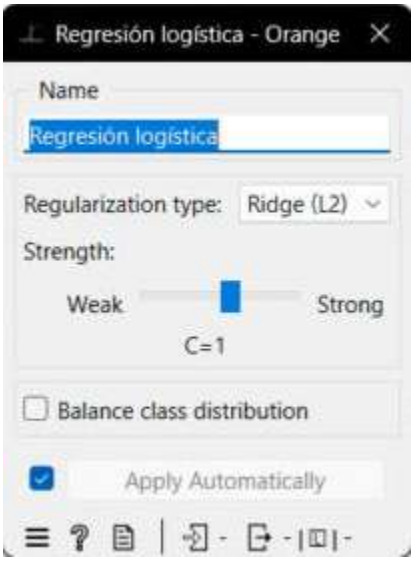


Figura 11. Widget Logistic Regression.

Tree «Árbol de decisión». «Induce binary tree» desmarcado; mínimo 2 instancias por hoja; no dividir subconjuntos menores de 5; profundidad máxima 100; parar cuando la mayoría alcanza 95 %.

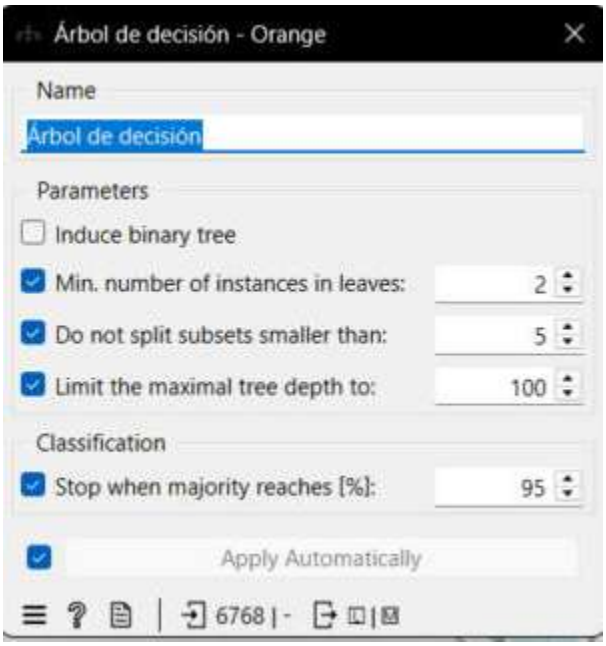


Figura 12. Widget Tree.

Random Forest. 100 árboles, no dividir subconjuntos menores de 5, «Replicable training» marcado, sin límite de profundidad ni de atributos.

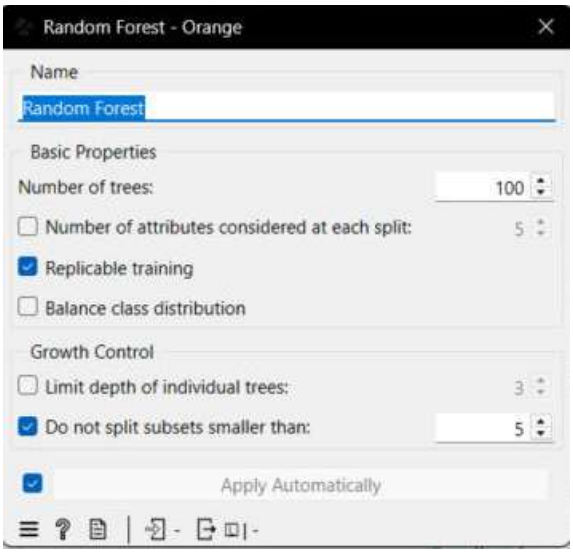


Figura 13. Widget Random Forest.

Test and Score «Validación cruzada 10 pliegues». Entradas: Data desde Select Columns, los 3 aprendices y el Preprocessor. Cross validation, 10 folds, Stratified; Target class = ELECTRICO.

Modelo	AUC	CA	F1	Precisión	Recall
Regresión logística	0,941	0,870	0,868	0,944	0,802
Random Forest	0,933	0,868	0,869	0,916	0,827
Árbol de decisión	0,904	0,845	0,850	0,871	0,829

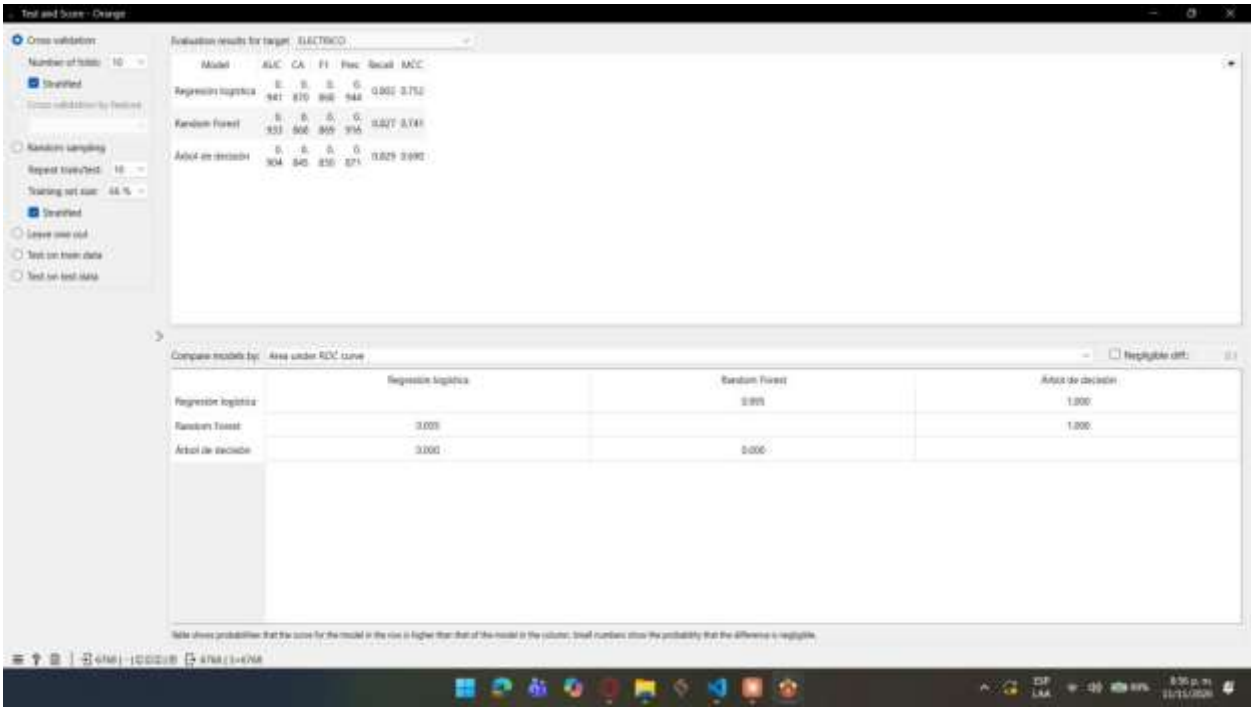


Figura 14. Test and Score con los tres modelos.

Confusion Matrix y ROC Analysis. Conectados a «Evaluation Results». La regresión logística acierta 2.875 eléctricos y 3.015 híbridos; clasifica 708 eléctricos como híbridos y 170 híbridos como eléctricos.

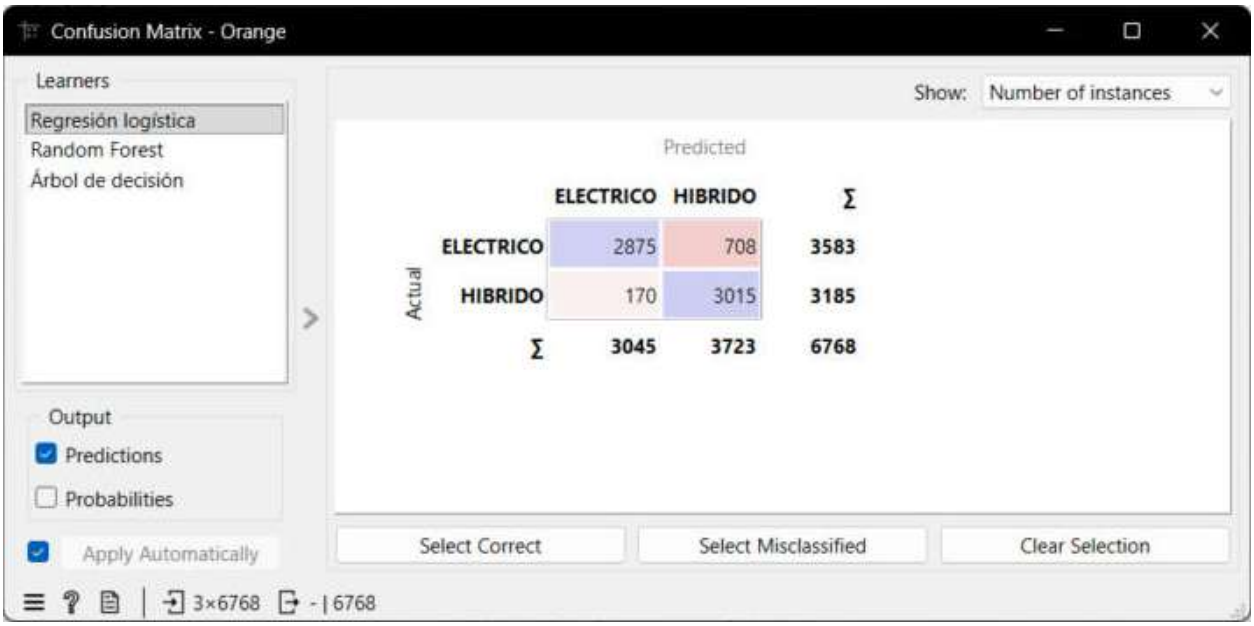


Figura 15. Matriz de confusión de la regresión logística.

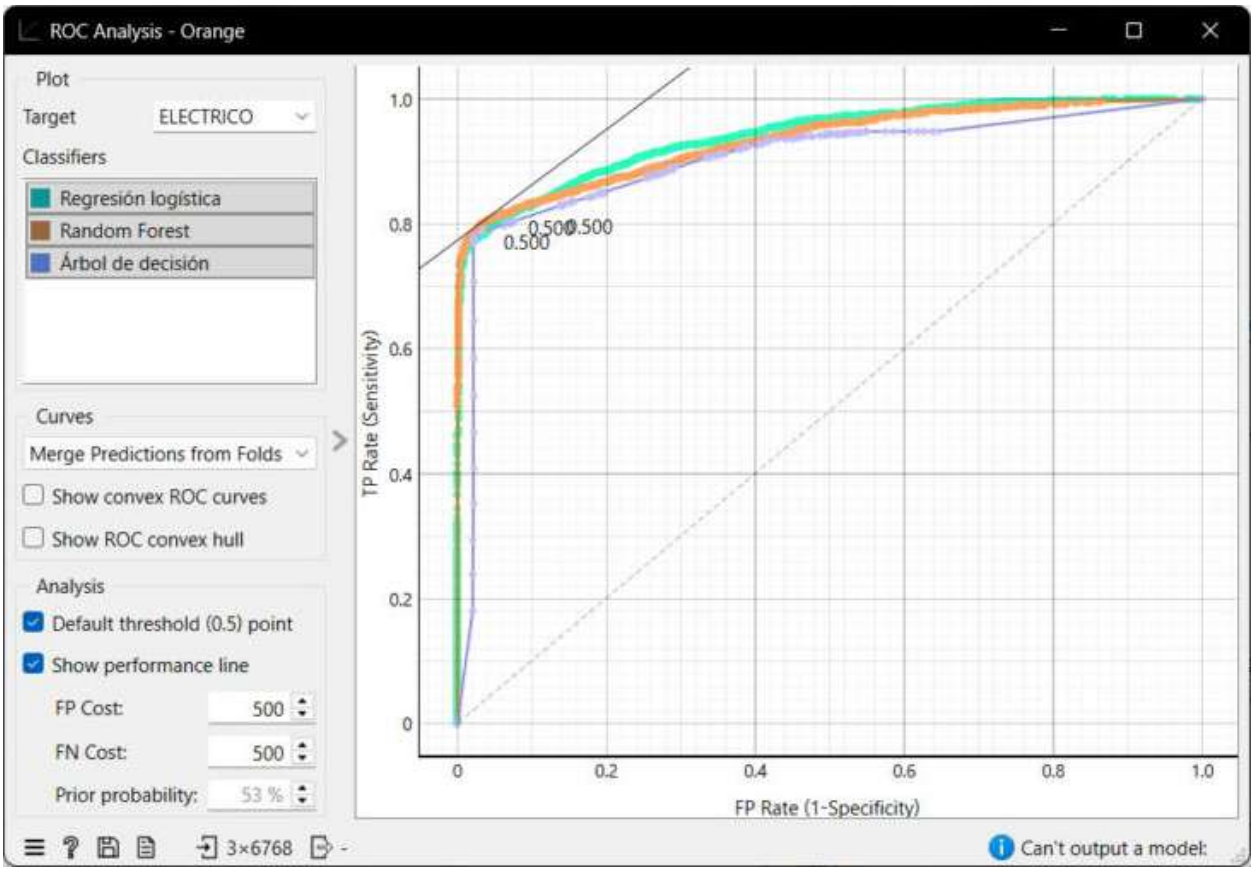


Figura 16. Curvas ROC de los tres modelos.

Tree Viewer. Recibe el «Model» del árbol: 972 nodos y 561 hojas según Orange (el script etapa6_modelos.py cuenta 973 y 562 sobre el mismo árbol; la diferencia de una unidad no se investigó), con carroceria en la raíz.

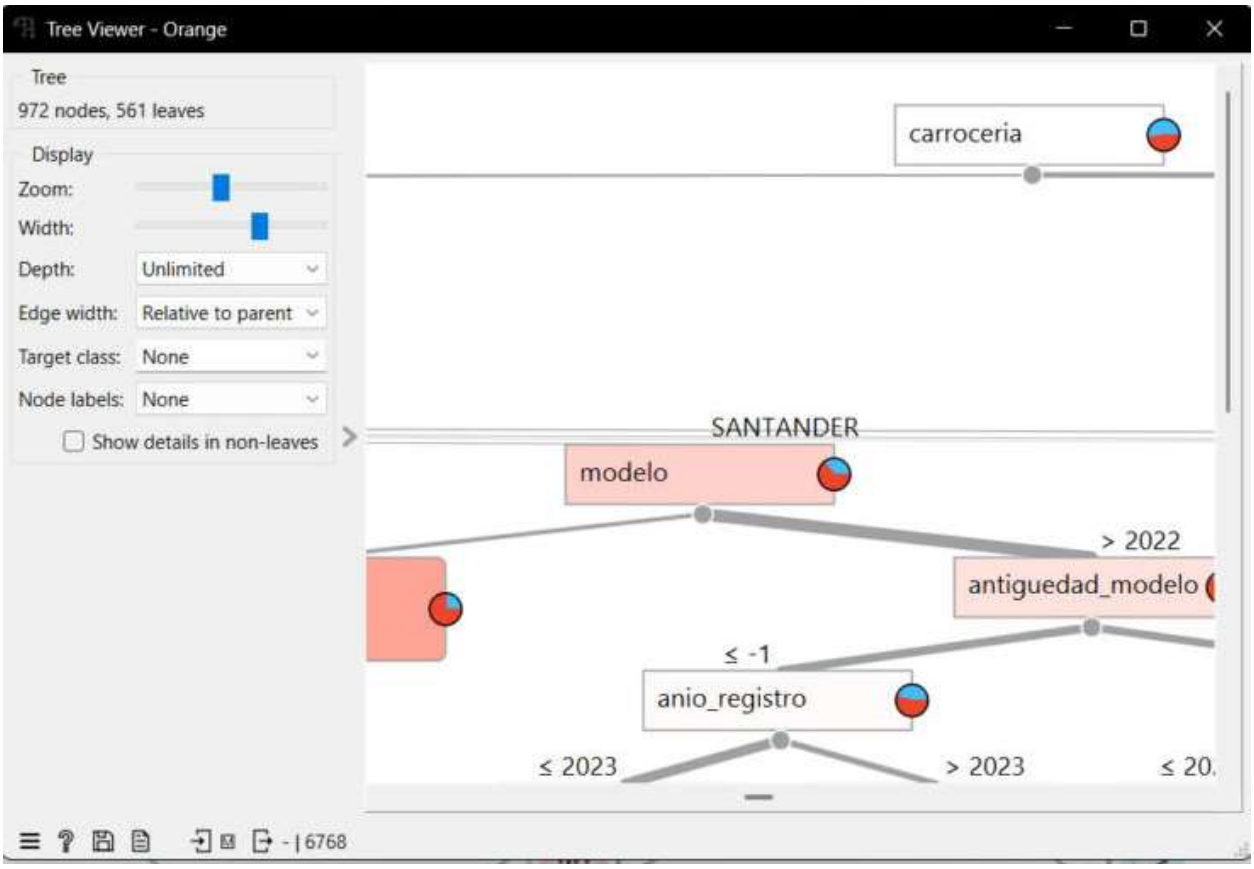


Figura 17. Tree Viewer.

Flujo 2 - Clustering: preparación de datos

La preparación convierte los 6.772 grupos en 98 territorios con al menos 30 vehículos, descritos por 8 variables. No se usan combustible ni tipo_motorizacion para formar los grupos. Los widgets File ×2 y Merge Data se copiaron del flujo 1 con la misma configuración.

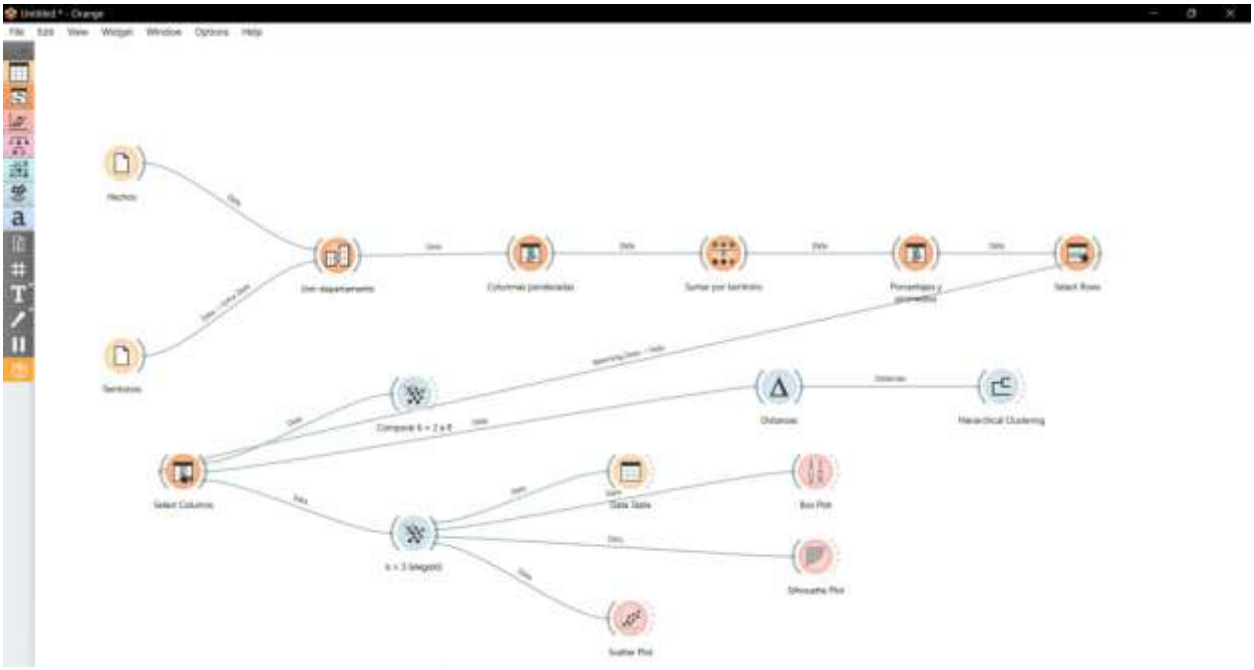


Figura 18. Lienzo del flujo 02_clustering.ows.

Formula «Columnas ponderadas». Siete columnas multiplicadas por cantidad, para sumar vehículos y no filas:

• w_cam, w_aut, w_cmp = cantidad * (clase == 'CAMIONETA' | 'AUTOMOVIL' | 'CAMPERO').

• w_mic = cantidad * (clase in (CICLOMOTOR, CUADRICICLO, CUATRIMOTO, MOTOCARRO, MOTOCICLETA, MOTOTRICICLO, TRICIMOTO)).

• w_rec = cantidad * (anio_registro >= 2022).

• w_anio = cantidad * anio_registro; w_antig = cantidad * (anio_registro - modelo).

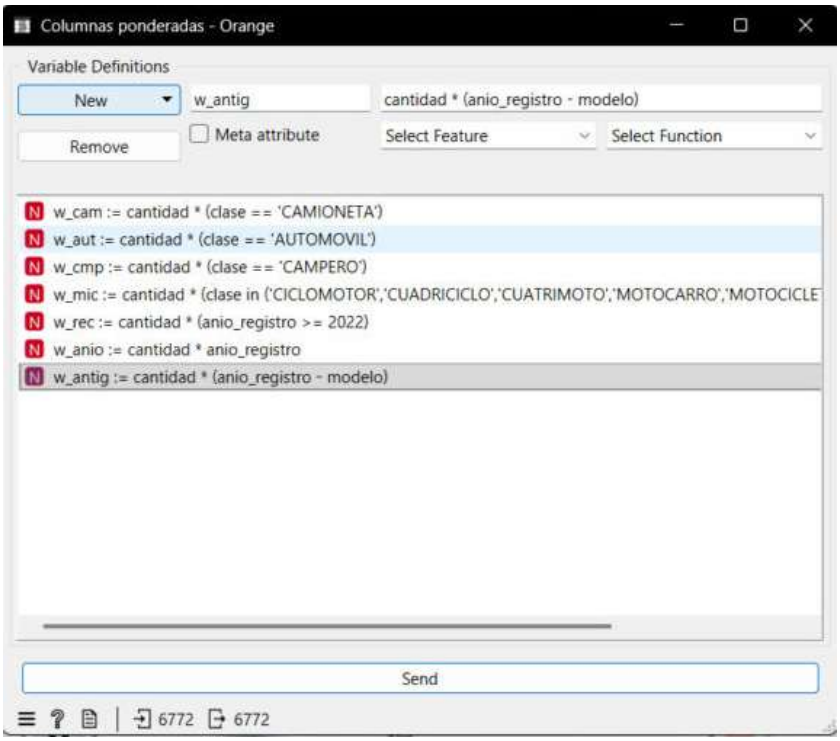


Figura 19. Formula «Columnas ponderadas».

Group by «Sumar por territorio». Agrupa por territorio y aplica solo Sum a cantidad y a las siete w_*; el resto de variables queda sin agregación. Salida: 247 filas.

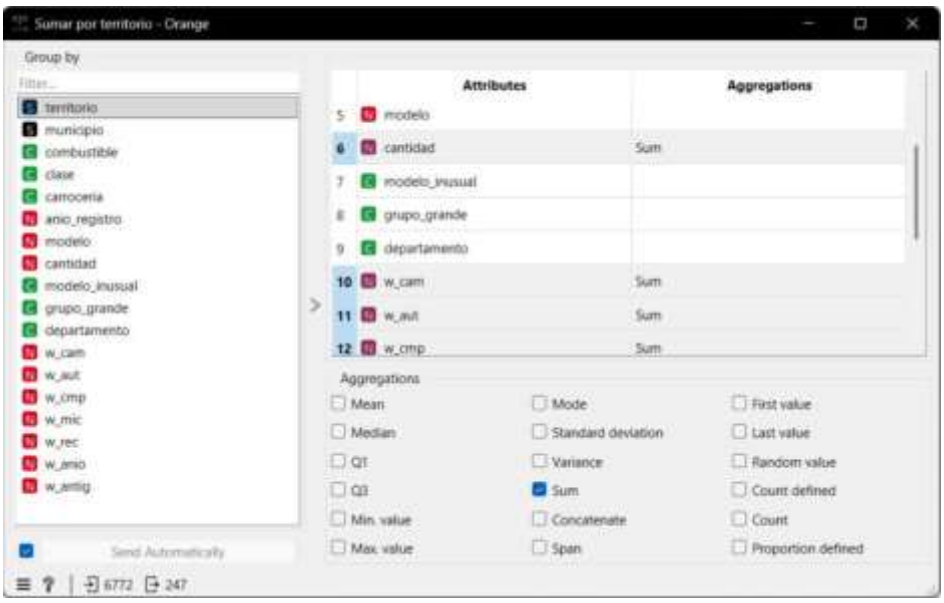


Figura 20. Group by con las agregaciones Sum.

Formula «Porcentajes y promedios». Nueve variables a partir de las sumas (Orange nombra «cantidad - Sum» como cantidad___Sum): vehiculos, log10_vehiculos, pct_camioneta, pct_automovil, pct_campero, pct_micromovilidad, pct_registro_2022_2024, anio_registro_medio y antiguedad_media.

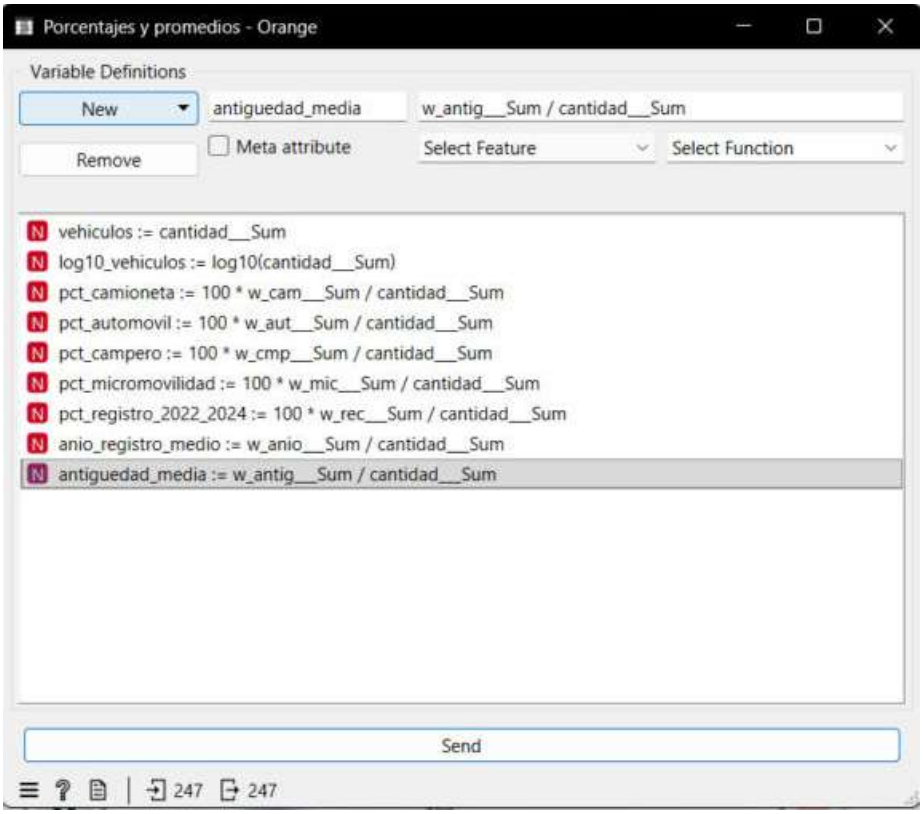


Figura 21. Formula «Porcentajes y promedios».

Select Rows. Condición vehiculos is at least 30. Quedan 98 territorios; los otros 149 tienen menos de 30 vehículos y darían porcentajes inestables.

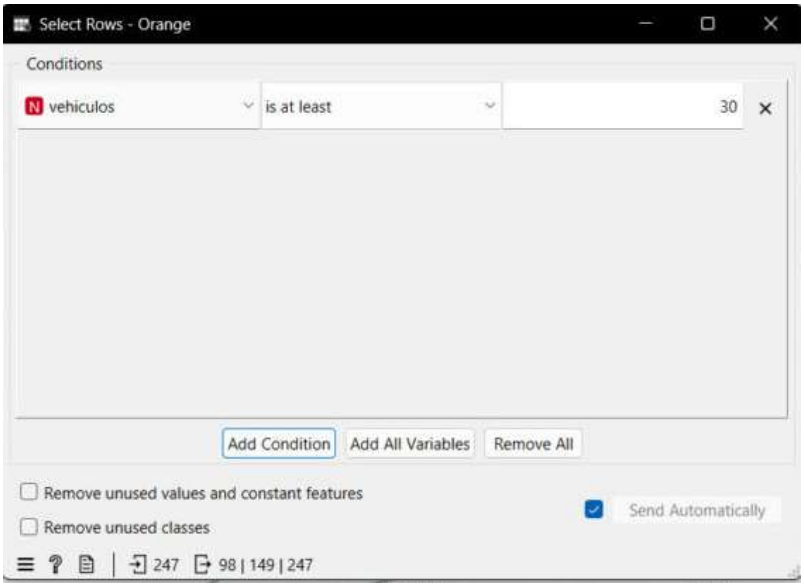


Figura 22. Select Rows (vehiculos ≥ 30).

Select Columns. Features: las 8 variables de perfil (log10_vehiculos, cuatro porcentajes de clase, pct_registro_2022_2024, anio_registro_medio y antiguedad_media). Metas: territorio y vehiculos. Sin target; las sumas quedan ignoradas.

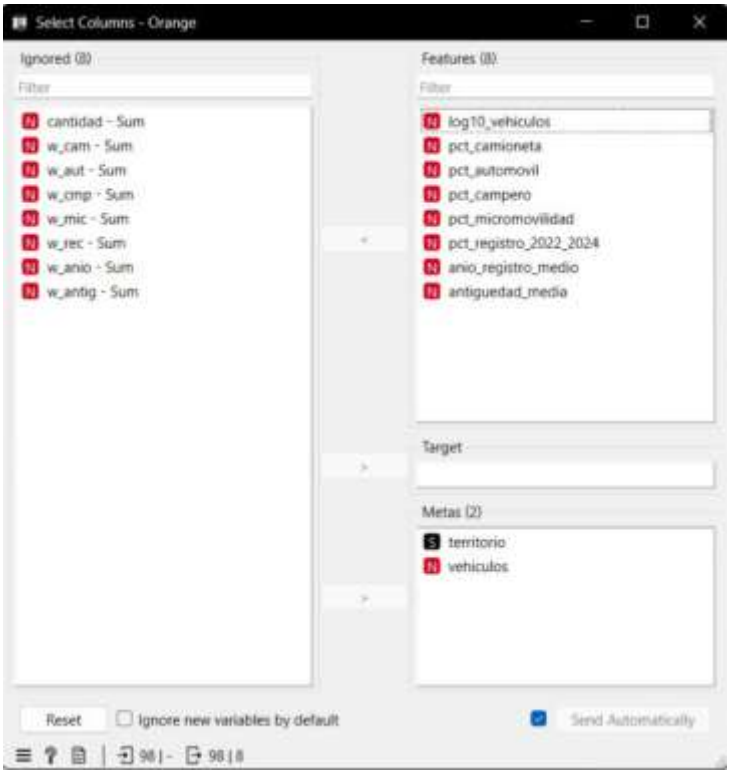


Figura 23. Select Columns del flujo 2.

Flujo 2 - Agrupamiento y visualización

Se eligió k = 3, que forma grupos de 22, 34 y 42 territorios. k = 2 tiene la silueta más alta (0,452), pero solo separa los territorios de micromovilidad (36) del resto (62), algo que ya se ve en los datos; k = 3 (0,286) conserva ese grupo, divide el resto en grandes centros y ciudades intermedias y es la mejor silueta entre los k ≥ 3. Es una elección de interpretabilidad: ambas siluetas indican una estructura débil a moderada.

k-Means «Comparar k = 2 a 8». «Optimize the number of clusters» de 2 a 8, Normalize columns marcado, inicialización KMeans++, 10 re-ejecuciones y 300 iteraciones máximas. Normalizar es obligatorio porque las variables tienen escalas muy distintas (porcentajes 0–100, años ≈ 2020, logaritmos 1–5).

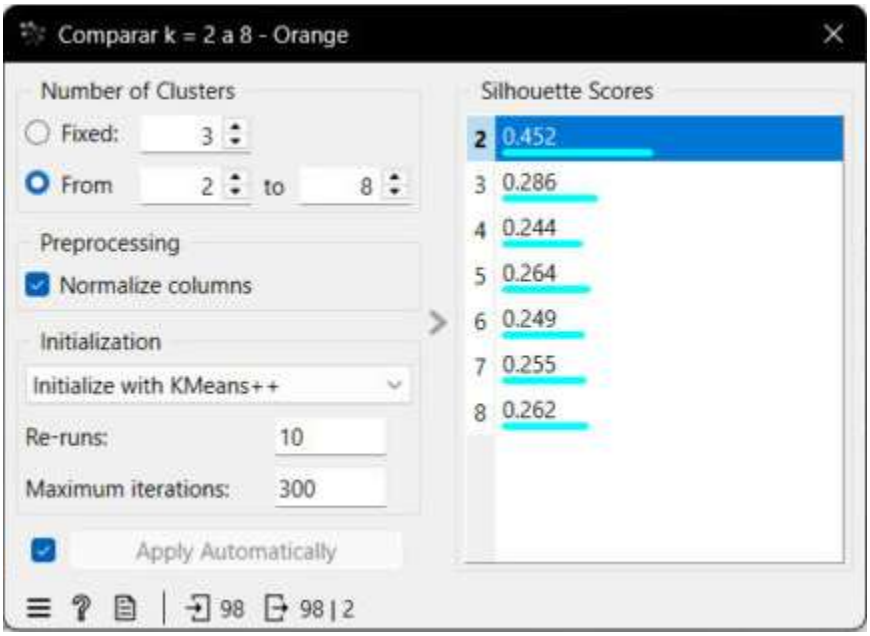


Figura 24. Silueta media para k = 2 a 8.

k-Means «k = 3 (elegido)». k fijo = 3 con las mismas opciones. Su salida «Data» alimenta Data Table, Scatter Plot, Box Plot y Silhouette Plot.

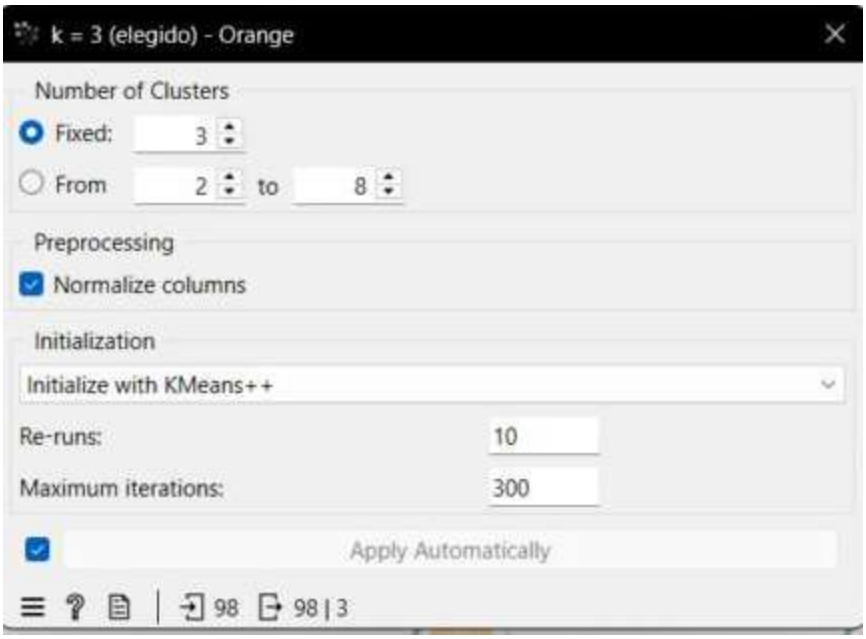


Figura 25. k-Means con k = 3.

Grupo	Territorios	Perfil
C1	22	Ciudades grandes (Bogotá, Medellín, Cali…); según resultados_etapa6_clustering.json reúnen ≈ 86,9 % de los vehículos
C2	34	Micromovilidad, media de 83,6 % (Madrid, Cartagena, Soacha…)
C3	42	Ciudades intermedias con camionetas (Girón, Pasto, Neiva…)

Scatter Plot. Eje x log10_vehiculos, eje y pct_camioneta, color por Cluster: los tres grupos se separan con claridad.

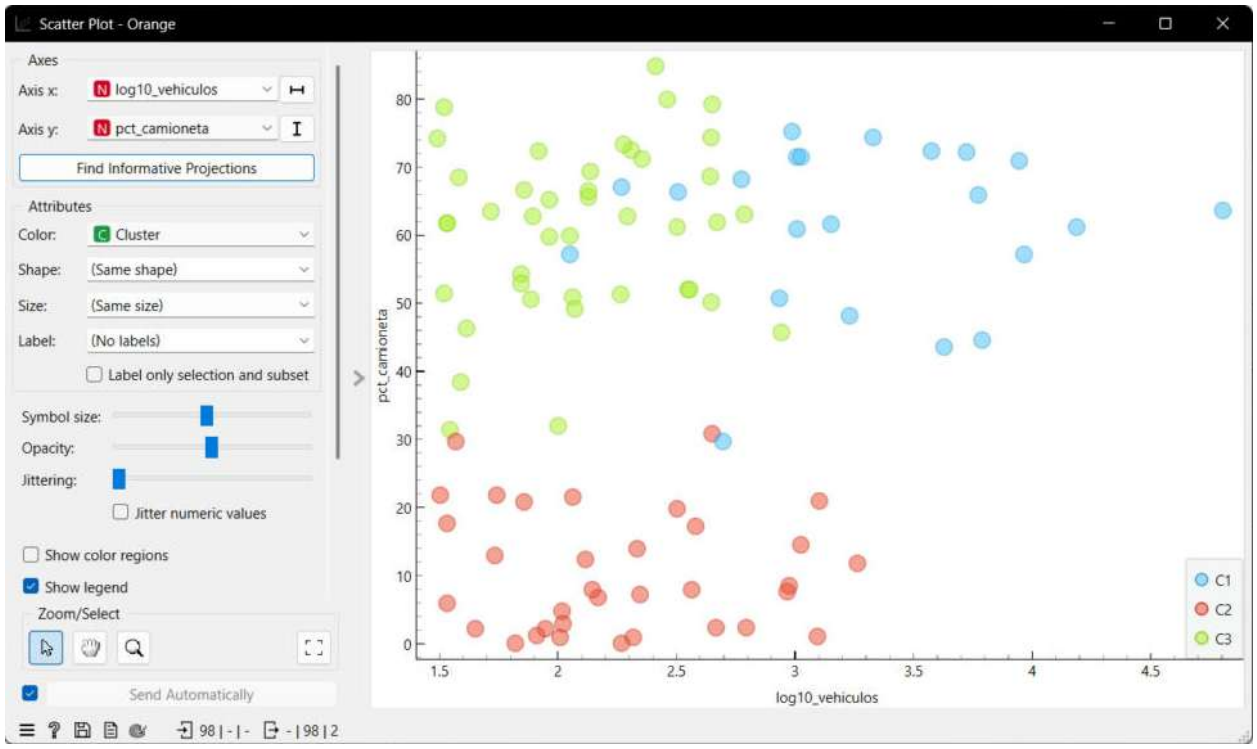


Figura 26. Scatter Plot coloreado por Cluster.

Box Plot. Variable pct_micromovilidad con subgrupos por Cluster. ANOVA = 224,0 ($p < 0,001$).

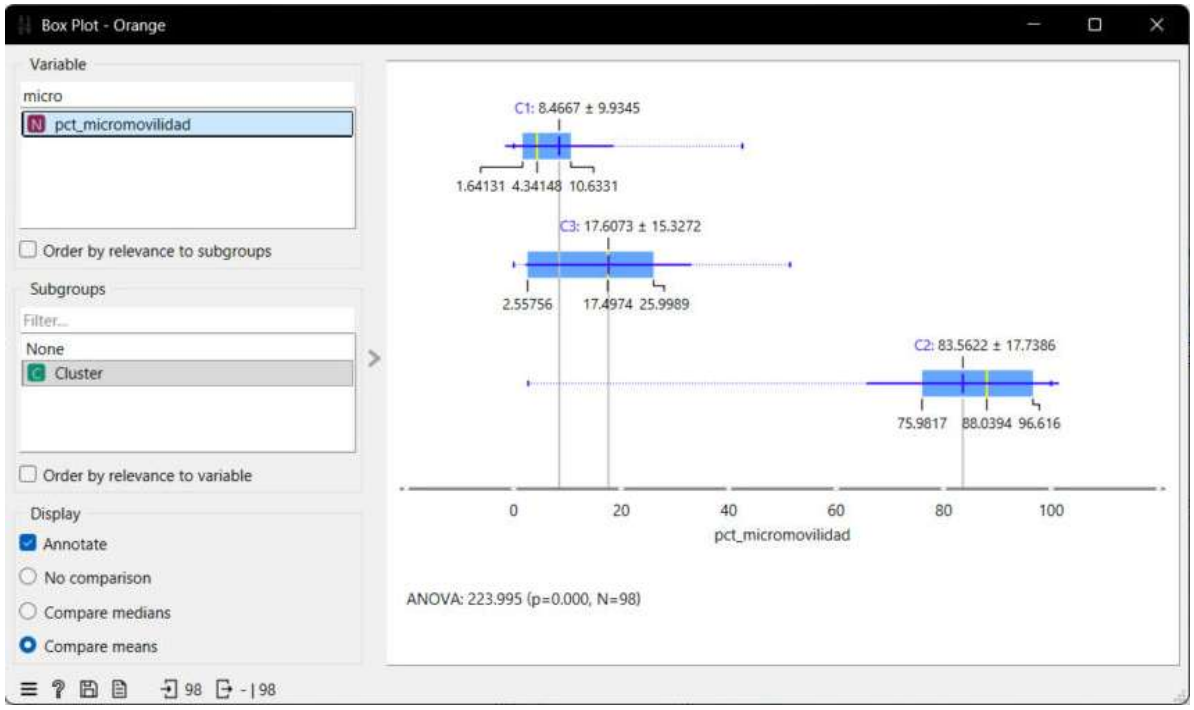


Figura 27. Box Plot de pct_micromovilidad por grupo.

Distances → Hierarchical Clustering. Desde Select Columns, distancia Euclidean (normalized) y enlace Ward, como comprobación del agrupamiento.

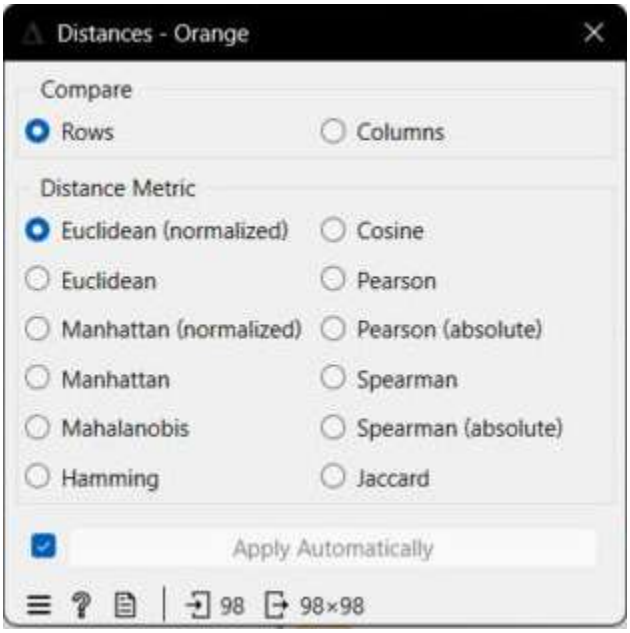


Figura 28. Widget Distances (euclidiana normalizada).

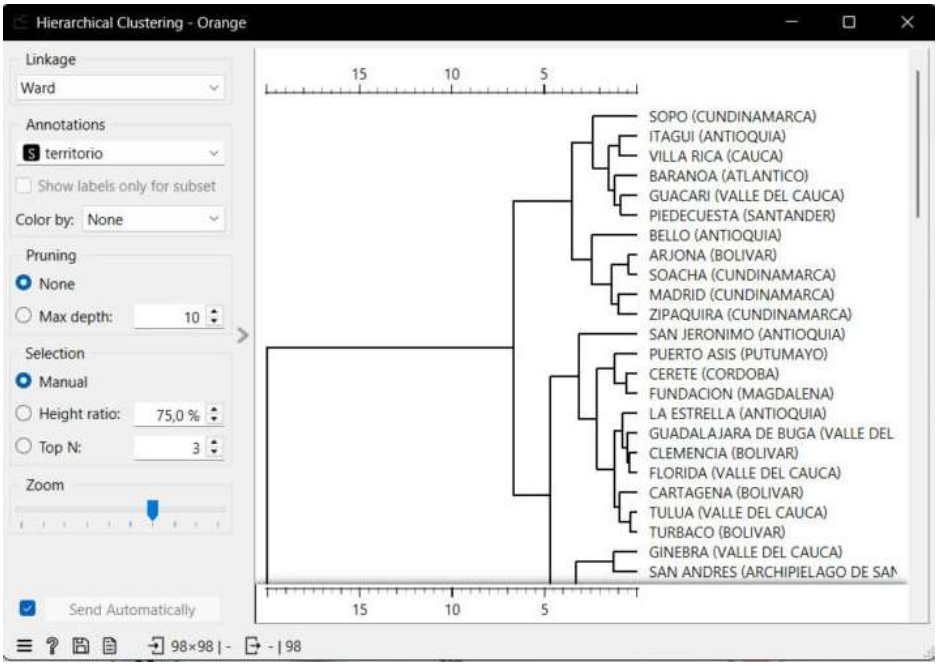


Figura 29. Dendrograma con enlace Ward.

Flujo 3 - Comentarios de YouTube

El corpus tiene 2.657 comentarios y, tras el preprocesamiento, un vocabulario de 1.690 términos. LDA con 3 temas y los bigramas resumen de qué se habla; no se muestran nombres de autores.

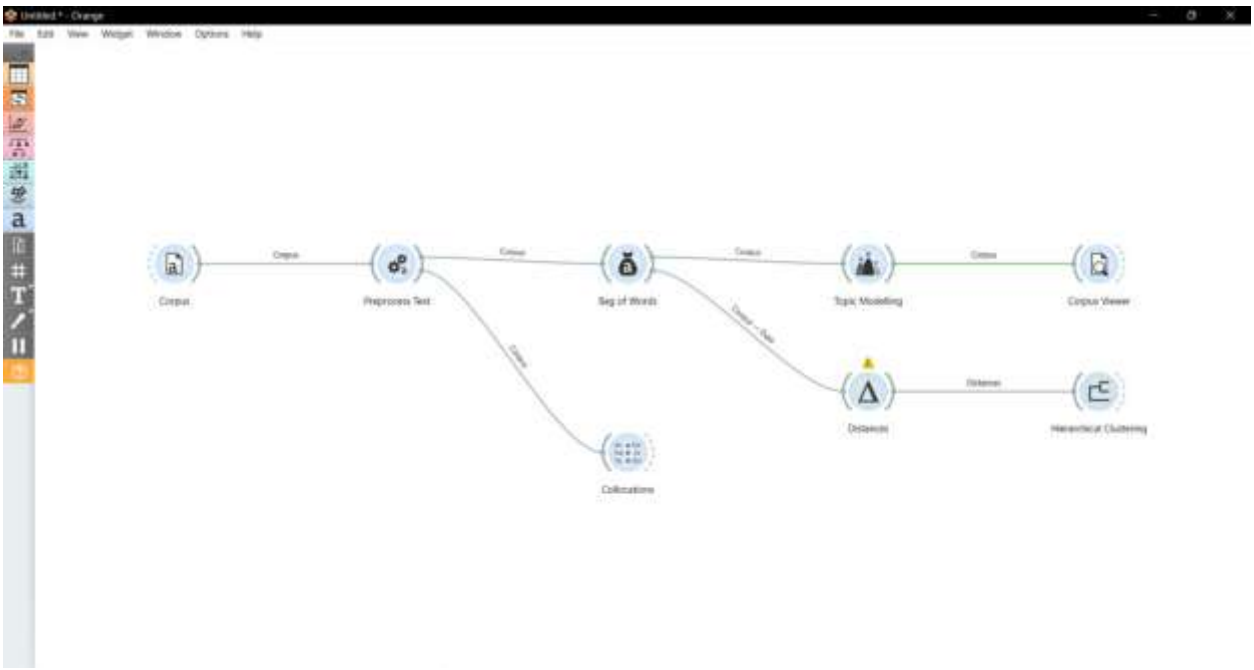


Figura 30. Lienzo del flujo 03_comentarios_youtube.ows.

Corpus. Carga data\processed\etapa6\comentarios_limpios.tab. Campo de texto texto, idioma Spanish; id_hash, video_id y fecha quedan como texto ignorado.

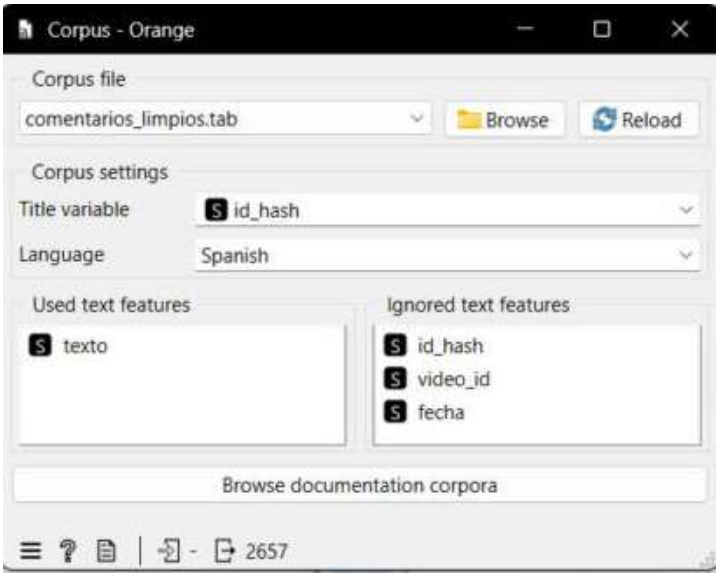


Figura 31. Widget Corpus.

Preprocess Text. Cuatro pasos en este orden:

1. Transformation: Lowercase, Remove accents y Remove urls.

2. Tokenization: Regexp \w+.

3. Normalization: Snowball Stemmer, idioma Spanish.

4. Filtering: Stopwords desde el archivo etapa6_stopwords_es.txt (idioma «none»), Numbers y Document frequency absoluta, mínimo 3 y máximo 100.000.

Salida: 29.221 tokens y 1.690 tipos.

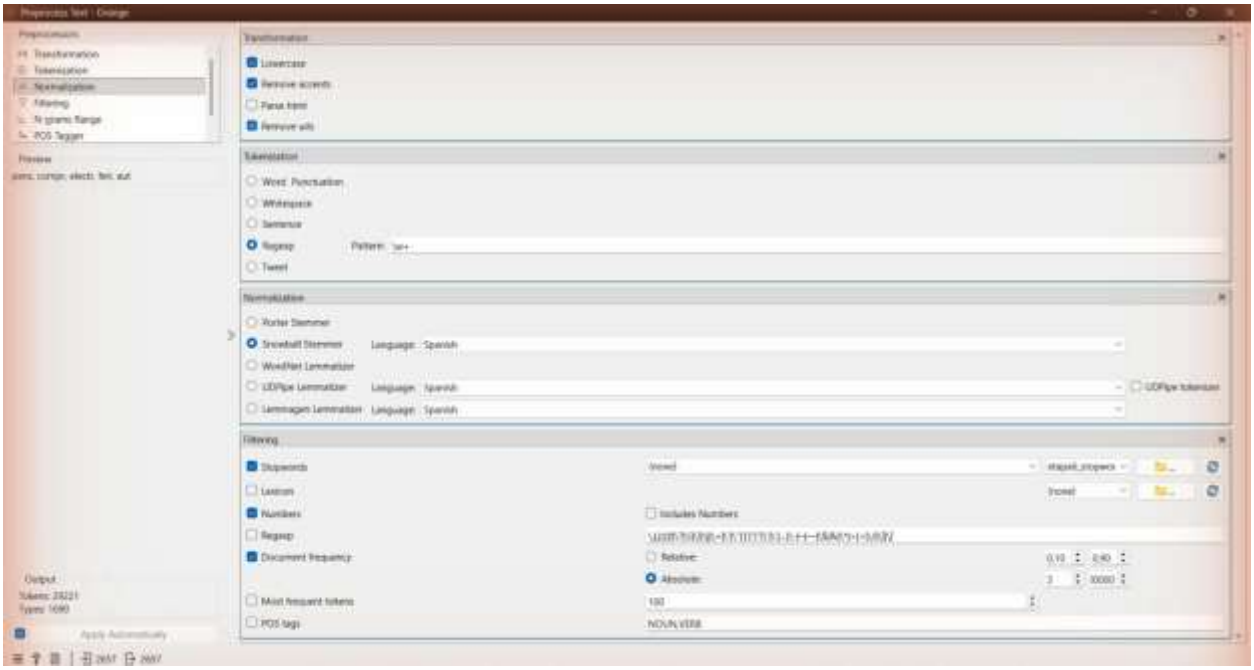


Figura 32. Preprocess Text con sus cuatro pasos.

Bag of Words. Term frequency Count, Document frequency IDF, Regularization L2 (Euclidean).

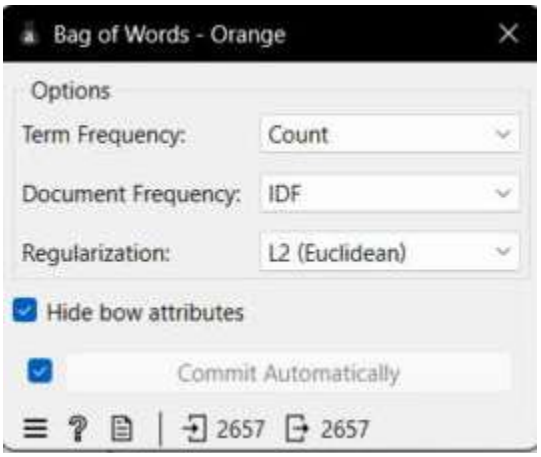


Figura 33. Widget Bag of Words.

Distances → Hierarchical Clustering. Desde Bag of Words con distancia Cosine, para ver agrupaciones de comentarios.

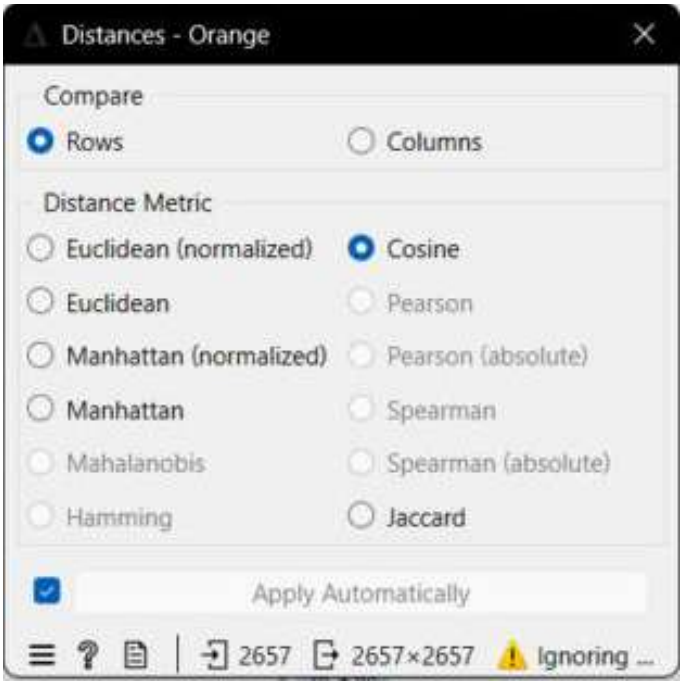


Figura 34. Widget Distances (coseno).

Topic Modelling. Método LDA con 3 temas (coherencia 0,40 según el widget; el script, con la medida c_v, obtiene 0,48 para k = 3: son cálculos distintos y no se comparan). Los temas obtenidos:

Tema	Palabras principales (en raíz)	Lectura
1	carg, hibr, compr, preci, electr, gasolin	Precio y compra: eléctrico, híbrido o gasolina
2	carr, plac, pic, repuest, chin, deepal	Carros, pico y placa, repuestos y marcas chinas
3	inform, bateri, cargador, cost, colombi	Baterías, cargadores y costos en Colombia

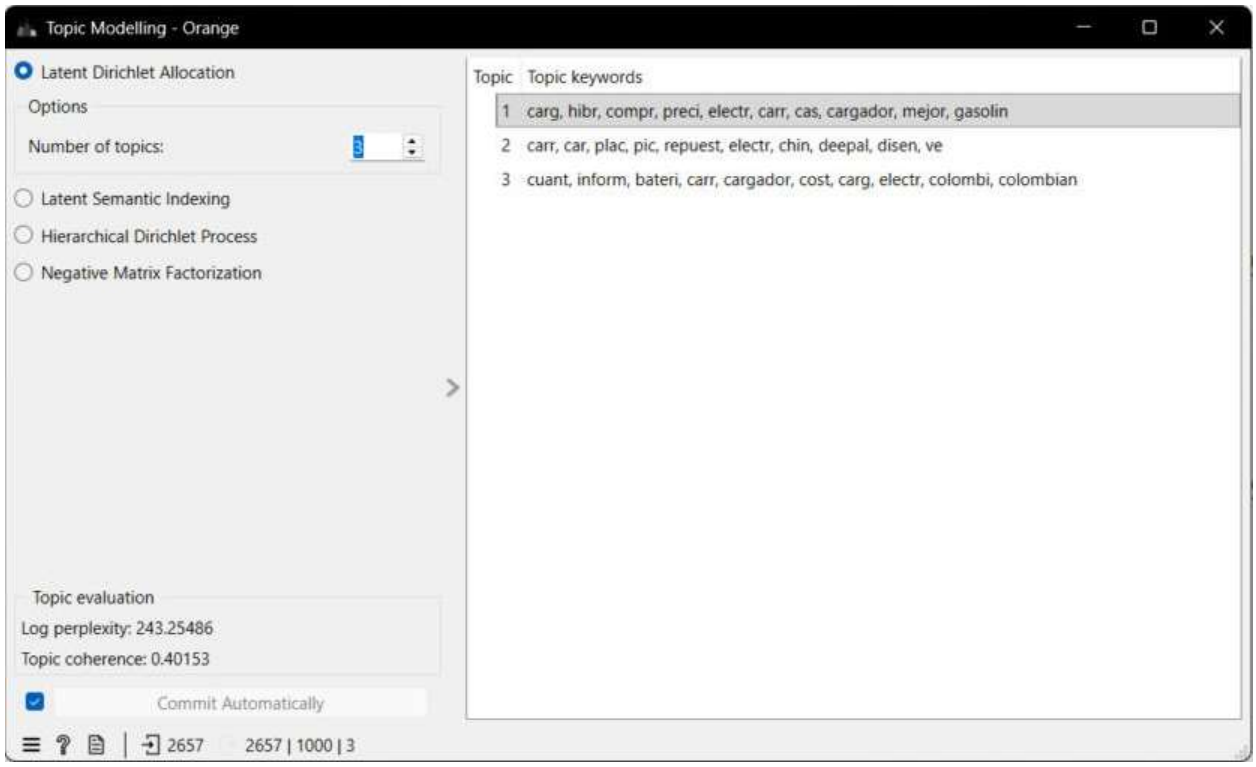


Figura 35. Topic Modelling con las palabras de cada tema.

Collocations. Desde Preprocess Text, bigramas con puntuación Raw Frequency. Los más frecuentes: carr electr, vehicul electr, aut electr, compr carr, pic plac, medi ambient y vid util.

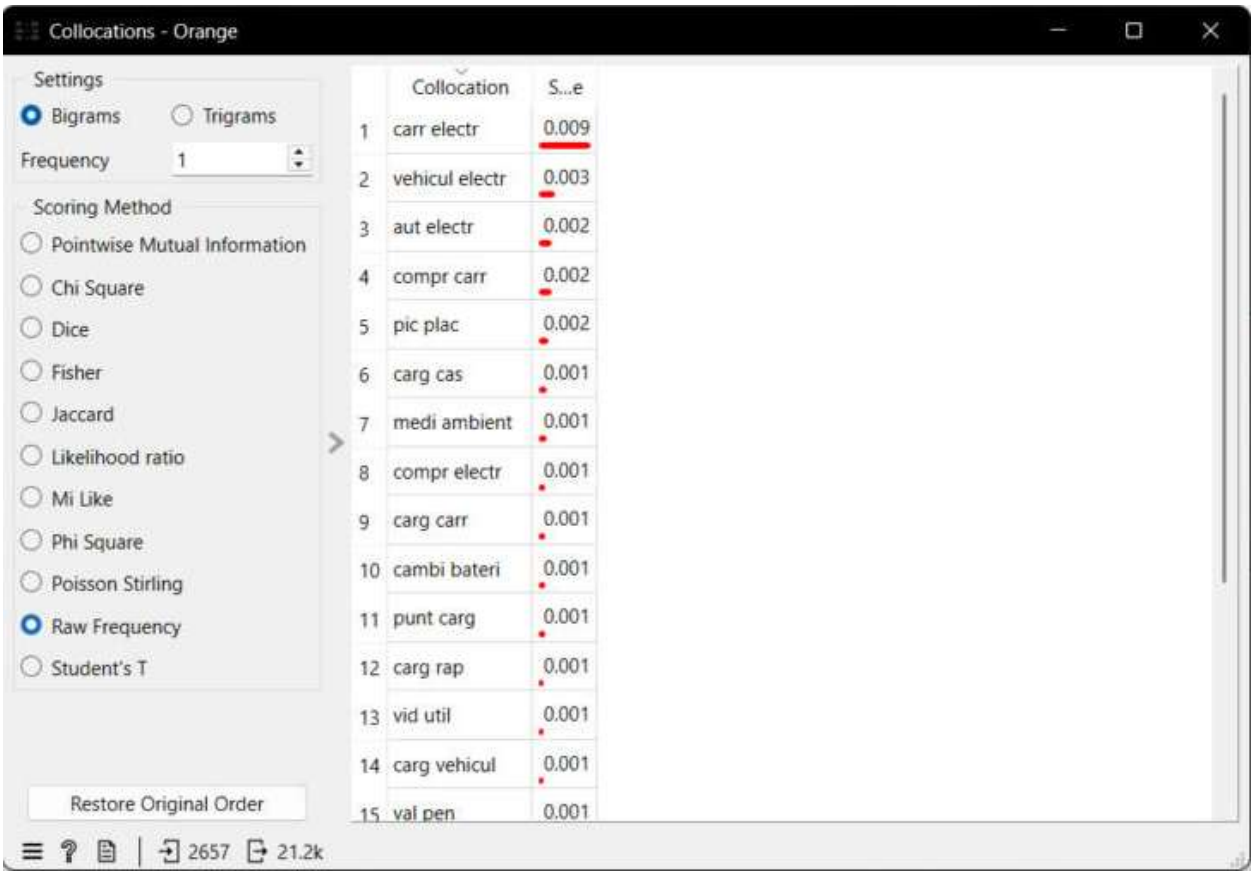


Figura 36. Collocations (bigramas más frecuentes).

Cifras obtenidas frente a las esperadas

Las cifras esperadas son las de los scripts del repositorio (resultados_etapa6_*.json). De 15 comprobaciones, 12 coinciden exactamente o dentro de la tolerancia; las otras tres (silueta de k = 4 y k = 5, bigramas y temas LDA) difieren levemente o se expresan distinto, como se explica en las observaciones.

Comprobación	Esperado	Obtenido
Filas tras quitar hidrógeno	6.768	6.768
ELECTRICO / HIBRIDO	3.583 / 3.185	3.583 / 3.185
Rank: carrocería / clase	0,554 / 0,468	0,554 / 0,468

Comprobación	Esperado	Obtenido
Regresión logística (AUC, CA)	0,941 / 0,870	0,941 / 0,870
Random Forest (Prec. / Recall)	0,914 / 0,829	0,916 / 0,827
Árbol (AUC / Prec.)	0,904 / 0,872	0,904 / 0,871
Matriz de confusión	2.875 / 708 / 170 / 3.015	2.875 / 708 / 170 / 3.015
Territorios agrupados	247	247
Territorios con ≥ 30 vehículos	98	98
Silueta k = 2, 3, 6, 7, 8	0,452 / 0,286 / 0,249 / 0,255 / 0,262	Iguales
Silueta k = 4 y k = 5	0,239 / 0,266	0,244 / 0,264
Tamaños con k = 3	22 / 34 / 42	22 / 34 / 42
Comentarios y vocabulario	2.657 / ≈ 1.690	2.657 / 1.690
Bigramas principales	carro eléctrico (≈ 139), carros eléctricos (≈ 118)…	carr electr, vehicul electr, pic plac…
Temas LDA	Baterías y carga; precio y compra; carga en casa	Precio y compra; pico y placa y repuestos; baterías y costos

Observaciones:

• Las diferencias en k = 4 y k = 5 (0,005 y 0,002) son leves y no cambian la elección de k = 3. El widget k-Means usa semilla fija, así que no se trata de azar; la causa exacta no se determinó.

• Los bigramas salen en raíz porque se aplica stemming antes de Collocations: «carr electr» junta «carro eléctrico» y «carros eléctricos», así que su frecuencia no se compara directamente con la del script etapa6_youtube_analisis.py, que cuenta las palabras completas.

• LDA tiene azar: los temas se parecen a los esperados, pero no son idénticos, y no se midió el porcentaje de comentarios por tema.

4. Resultados del aprendizaje supervisado

Tipo de problema. Clasificación binaria, porque la variable objetivo (tipo_motorizacion) es una categoría y no una cantidad. Desbalance. Por grupo hay 52,9 % de eléctricos y 47,1 % de híbridos (casi balanceado), pero por vehículo los eléctricos son solo 23,7 %. Por eso se reportan las dos vistas y, por vehículo, el accuracy se compara con la línea base «siempre híbrido» (0,763) y no con 0,5.

Comparación por grupo (lo que muestra Test and Score; validación cruzada estratificada de 10 pliegues, clase positiva ELÉCTRICO):

Modelo	Accuracy	Precisión	Recall	F1	AUC	Accuracy en grupos grandes
Regresión logística (elegido)	0,870	0,944	0,802	0,868	0,941	0,882
Random Forest	0,868	0,914	0,829	0,869	0,933	0,834
Árbol de decisión	0,845	0,872	0,829	0,850	0,903	0,791
Línea base (clase mayoritaria)	0,529					

Ponderado por vehículo (cada grupo pesa su cantidad; mismas predicciones de la validación cruzada):

Modelo	Accuracy	Precisión	Recall	F1	AUC
Regresión logística	0,881	0,773	0,709	0,740	0,900
Random Forest	0,665	0,376	0,623	0,469	0,735
Árbol de decisión	0,583	0,313	0,631	0,418	0,702
Línea base (siempre híbrido)	0,763				

Matriz de confusión de la regresión logística. Por grupo: 2.875 eléctricos bien clasificados, 708 eléctricos clasificados como híbridos, 170 híbridos clasificados como eléctricos y 3.015 híbridos bien clasificados. Por vehículo, 10.765 eléctricos se clasifican como híbridos y 7.689 híbridos como eléctricos.

Selección de variables. El ranking por ganancia de información deja arriba la carrocería (0,554) y la clase (0,468); departamento, año de registro, año del modelo y antigüedad quedan por debajo de 0,07. Se conservaron las seis predictoras.

Modelo seleccionado: regresión logística.

• Desempeño. Por grupo empata con el Random Forest (accuracy 0,870 frente a 0,868) y supera al árbol (0,845). Por vehículo es claramente el mejor (0,881 frente a 0,665 del bosque y 0,583 del árbol) y el único que supera la línea base (0,763). El árbol y el bosque son menos exactos en los grupos grandes (0,791 y 0,834 frente a 0,882), que concentran el 88 % de los vehículos.

• Errores. Su error típico es perdonar eléctricos: precisión 0,944 pero recall 0,802. En automóviles y camionetas, donde conviven ambos tipos, el recall baja a 0,393.

• Interpretación y utilidad. Es un modelo lineal con coeficientes legibles; el árbol completo tiene 973 nodos y 562 hojas y no se puede leer. Aporta un conocimiento claro: el tipo de motorización

se deduce sobre todo de qué tipo de vehículo es (ciclomotores, cuadriciclos y motocarros son eléctricos; los camperos, híbridos); el territorio y el año casi no ayudan.

• Limitaciones. Los 6.768 grupos corresponden a solo 2.980 combinaciones distintas de predictoras y 364 de ellas tienen eléctricos y híbridos a la vez (ambigüedad irreducible); combinaciones idénticas pueden caer en entrenamiento y prueba, así que la validación es optimista para combinaciones nuevas. No hay marca, precio ni potencia, y no se evaluó hacia el futuro: son asociaciones, no causas.

5. Resultados del clustering

Algoritmo y parámetros. k-Means de Orange con las 8 variables normalizadas, inicialización k-means++, 10 re-ejecuciones y 300 iteraciones. Se compararon k = 2 a 8 con la silueta media (Tabla siguiente).

k	Silueta media	Inercia	Tamaños de los grupos
2	0,452	379,3	62 - 36
3 (elegido)	0,286	320,8	22 - 34 - 42
4	0,239	268,6	20 - 19 - 39 - 20
5	0,266	225,3	31 - 19 - 17 - 16 - 15
6	0,249	203,3	15 - 12 - 19 - 15 - 15 - 22
7	0,255	190,5	12 - 10 - 20 - 19 - 13 - 15 - 9
8	0,262	175,9	3 - 11 - 18 - 11 - 12 - 13 - 18 - 12

Elección de k. La silueta más alta es la de k = 2 (0,452), pero solo separa los territorios de micromovilidad (36) del resto (62). k = 3 (0,286) conserva ese grupo, divide el resto en grandes centros e intermedios y es la mejor silueta entre los $k \geq 3$. Es una elección de interpretabilidad: ambas siluetas indican una estructura débil a moderada. Una comprobación con agrupamiento jerárquico (Ward) coincide solo en parte (índice de Rand ajustado 0,685).

Grupo	Terr.	% veh.	% cam.	% aut.	% micro	% 22–24	Antig.	% eléc.*
1. Grandes centros urbanos	22	86,9 %	61,5	24,4	8,5	79,1	-0,46	17,8
2. Territorios de micromovilidad eléctrica	34	7,8 %	10,6	2,9	83,6	45,9	0,14	87,7
3. Ciudades intermedias con parque de camionetas	42	5,3 %	60,9	14,7	17,6	75,6	-0,43	21,6

* Variable ilustrativa: no se usó para formar los grupos. Terr. = territorios; % cam. = camioneta; aut. = automóvil; micro = micromovilidad; 22–24 = registrado en 2022–2024; Antig. = antigüedad media (años).

• Grupo 1, grandes centros urbanos. 22 territorios con el 86,9 % de los vehículos (Bogotá, Medellín, Envigado, Cali, Funza): parque reciente de camionetas y automóviles.

• Grupo 2, micromovilidad eléctrica. 34 territorios donde dominan ciclomotores, cuadriciclos y motos (83,6 %); casi todo eléctrico (87,7 %) (Madrid, Cartagena, Arjona, Zipaquirá, Soacha).

• Grupo 3, ciudades intermedias. 42 territorios con perfil parecido al de los grandes centros pero con volúmenes pequeños y algo más de camperos (Girón, Pasto, Restrepo, Neiva, Armenia). Es el grupo menos nítido (silueta media 0,137).

Patrón oculto y uso. Hay dos formas distintas de adoptar vehículos eléctricos: la de los grandes centros y la de territorios medianos donde lo que se registra es micromovilidad; un promedio nacional las mezcla. Podría orientar medidas diferenciadas (carga pública para automóviles y camionetas; infraestructura y regulación para vehículos livianos). Limitaciones: estructura débil a moderada; la micromovilidad está casi perfectamente ligada al combustible eléctrico, así que

los grupos reflejan en parte la mezcla de clases ya conocida; no hay población, ingresos ni infraestructura de carga; 149 territorios pequeños quedaron fuera.

6. Comentarios de YouTube

6.1 Extracción con la API

Propósito. El RUNT dice cuántos vehículos se registran y dónde, pero no por qué las personas eligen o descartan uno u otro. Los comentarios de videos colombianos permiten explorar barreras y motivaciones (precio, carga, incentivos, desconfianza) y contrastarlas con los datos.

Procedimiento. Se usó la YouTube Data API v3 (search.list, videos.list, channels.list y commentThreads.list) con una clave propia, que no se publica (se lee de una variable de entorno). Fecha de extracción: 2026-11-11 23:57 UTC. Se hicieron 8 búsquedas en español (región CO): «carros eléctricos Colombia»; «carros híbridos Colombia»; «carro eléctrico o híbrido cuál comprar Colombia»; «cargadores carros eléctricos Colombia»; «ventajas y desventajas carro eléctrico Colombia»; «cuánto cuesta un carro eléctrico en Colombia»; «carro eléctrico Bogotá cargar en casa»; «híbrido enchufable Colombia reseña». Criterios de selección: videos publicados desde 2020-01-01, con al menos 50 comentarios, de contenido colombiano (canal con país declarado CO o título que menciona Colombia, Bogotá o Medellín), máximo 3 videos por canal y 20 en total, y hasta 500 comentarios de primer nivel por video ordenados por relevancia.

Resultado. La API devolvió 66 videos; 29 tenían pocos comentarios y 12 no eran de contenido colombiano. Se consultaron 20 videos y se obtuvieron 2.909 comentarios (cuota usada: 844 unidades de 10.000 diarias).

Video (enlace)	Canal	Publicado	Comentarios
Los problemas de comprar carro eléctrico en Colombia	W Radio Colombia	2023-10-19	500
Venta de carros eléctricos se disparó en Colombia: ¿qué ventajas ofrecen estos vehículos?	Noticias Caracol	2026-03-19	349

Video (enlace)	Canal	Publicado	Comentarios
El Nuevo Auto Eléctrico de Colombia Podría Acabar con Toda la Industria de Autos Eléctricos	Auto Total	2026-10-25	500
Miles de Colombianos Están VENDIENDO Sus Autos Eléctricos en 2026 — Y Esta es la Razón	Auto Total	2026-10-10	325
Que se necesita para cargar un carro eléctrico durante un viaje? te comparto mi experiencia de uso	Viviendo Verde	2024-08-10	132
LA VERDAD SE HA DICHO: José Clopatofsky habla de la realidad de los vehículos eléctricos e híbridos	RED MÁS Noticias	2026-01-30	230
Cupra Formentor Híbrido 💧 ¡Eficiente y deportivo a la vez! ⚡ Review (4K)	Autosdeprimera	2025-06-07	111
GAC Emkoo Hybrid ⚡ Moderno, diferente y muy eficiente 🔋 Review (4K)	Autosdeprimera	2025-03-12	102
Por esto compré una DEEPAL S07 de Rango Extendido 😍 ⚡	El Carro Colombiano	2026-06-07	112
CUPRA Formentor PHEV 💧 ¡Un tote de Crossover Hatch! 🔋 ⚡ Prueba - Reseña (4K)	Autosdeprimera	2025-01-19	64
Todo lo que tienes que saber sobre la carga de un vehiculo eléctrico - cargadores y convertidores	Viviendo Verde	2025-03-24	130

Video (enlace)	Canal	Publicado	Comentarios
¿Cuánto cuesta cargar un auto eléctrico en Bogotá, Colombia? analizamos los números del BYD Seagull	Viviendo Verde	2024-07-02	58
Ventas históricas en carros híbridos y eléctricos en Colombia: un mercado que está en tendencia	Noticias Caracol	2026-10-27	31
ASÍ ES EL HÍBRIDO ENCHUFABLE MÁS BARATO - BYD Yuan UP DM-i | Reseña	CarshopGaraje	2026-07-23	47
Estas son las dificultades al momento de cargar un vehículo eléctrico en Bogotá: así funciona	Noticias Caracol	2025-11-27	52
Los 6 carros eléctricos más baratos en Colombia que sí valen la pena	NovaGen	2025-06-17	49
TOP 10 HIBRIDOS MAS VENDIDOS EN COLOMBIA 2025: ¿VALEN LA PENA UN HIBRIDO en 2026?	WillGets	2026-01-21	22
¡ESTOS SON LOS SITIOS PARA CARGAR TU CARRO ELÉCTRICO EN BOGOTA! 🚗⚡ (Parte 1)	Typson Sanchez	2024-06-19	22
Estos son los carros híbridos y eléctricos más VENDIDOS en Colombia	RevistaSemana	2026-09-12	43
El SUV eléctrico más económico: MG S5 EV, reseña completa y #Testdrive en su llegada a Colombia	Los Electricos	2026-03-25	30

Restricciones encontradas:

• Solo comentarios de primer nivel: las respuestas no se descargan.

• Orden «relevance»: el tope por video (500) conserva los comentarios más relevantes, no una muestra aleatoria.

• La API no informa el país de quien comenta: aun en videos colombianos pueden comentar usuarios de otros países de habla hispana.

• La API no entrega todos los comentarios de un video con muchas respuestas ni los comentarios retenidos/eliminados.

• Cuota diaria de la API (10.000 unidades por proyecto): limita cuántas consultas y videos se pueden recolectar.

• 2 videos alcanzaron el tope de 500 comentarios, por lo que la muestra no es aleatoria.

6.2 Preparación y limpieza

Antes de contar, se eliminaron del texto las URL, correos, @menciones y celulares; no se guardan nombres, canales ni fotos de los autores (solo texto, «me gusta», fecha y un identificador anónimo). Las reglas se aplicaron en este orden:

Regla	Decisión	Comentarios eliminados
Vacíos	Sin texto o sin letras después de limpiar (solo emojis o signos)	13
Publicidad	Spam y promoción (WhatsApp, inversión, sorteos, «suscríbete»…)	27
Muy cortos	Menos de 4 palabras: no aportan tema	148
Duplicados	Mismo texto sin mayúsculas, tildes ni signos: se conserva el primero	5

Regla	Decisión	Comentarios eliminados
Otro idioma	Idioma distinto de español con probabilidad ≥ 0,90 (se excluye, no se traduce)	59
Comentarios analizados	91,3 % de los extraídos	2.657

El 64,2 % de los comentarios conservados menciona el tema de forma explícita; el resto se mantiene pero se marca, porque descartar por tema sería un juicio humano que conviene auditar. El análisis se hace en español (stopwords y stemmer en español). La mediana es de 18 palabras por comentario.

6.3 Análisis de texto

Se aplicó el flujo de Orange descrito en la sección 3: minúsculas, sin tildes ni URL, tokens por expresión regular, stemmer Snowball en español, stopwords en español (lista de NLTK más palabras propias, transformada igual que el texto para que el filtro funcione después del stemmer), sin números y términos presentes en al menos 3 comentarios. Quedan 1.690 términos. Se usaron tres lecturas complementarias:

a) Categorías de interés (definidas antes de ver los datos; codificación por diccionario, aproximada):

Categoría	Comentarios	% del total
Menciona eléctricos	711	26,8 %
Precio y costo	496	18,7 %
Carga e infraestructura	477	17,9 %
Batería y autonomía	335	12,6 %
Comparación con gasolina	312	11,7 %

Categoría	Comentarios	% del total
Desconfianza y problemas	232	8,7 %
Territorio y ciudad	210	7,9 %
Marcas y modelos	205	7,7 %
Ambiente	173	6,5 %
Menciona híbridos	171	6,4 %
Incentivos e impuestos	119	4,5 %
Mantenimiento y repuestos	104	3,9 %
Micromovilidad (motos, scooters)	28	1,1 %

b) Términos y expresiones. Más frecuentes: electrico (693), carro (610), carga (324), comprar (292), colombia (283), vehiculo (259), bateria (253), mejor (184), gasolina (179), casa (171). Bigramas: carro electrico (139); carros electricos (118); vehiculos electricos (52); pico placa (47); medio ambiente (36); autos electricos (34); auto electrico (33); vehiculo electrico (31).

c) Temas (LDA). Se compararon k = 3 a 8 con la coherencia c_v y se eligió k = 3 (coherencia 0,480). Es una coherencia moderada: los temas se solapan y conviene leerlos como tendencias, no como grupos cerrados.

Tema	Palabras principales (raíz visible)	% de comentarios	Lectura
1	carga, electrico, casa, carro, hibrido, cargador, comprar, vehiculo	30,0 %	Baterías, carga y costos de cargar

Tema	Palabras principales (raíz visible)	% de comentarios	Lectura
2	electrico, carro, colombia, comprar, precio, vender, vehiculo, gasolina	34,5 %	Precio y compra de eléctricos frente a gasolina, en Colombia
3	bateria, carga, cargador, carro, cuanto, electrico, colombia, vehiculo	35,5 %	Carga en casa, instalación y híbridos

Por privacidad, el informe no reproduce comentarios textuales: todo se sustenta con conteos y términos.

6.4 Qué aportan los comentarios

• Información nueva. Marcas y modelos aparecen en el 7,7 % de los comentarios y el RUNT no trae marca; además, precio (18,7 %), carga (17,9 %) y batería (12,6 %) son las preocupaciones más frecuentes, algo que el registro no puede mostrar.

• Cuestionan los datos. Se habla de eléctricos en el 26,8 % de los comentarios y de híbridos en el 6,4 %, mientras el RUNT registra 76,3 % de híbridos entre los vehículos. La conversación no refleja lo que se matricula (en parte porque las búsquedas decían sobre todo «eléctrico»).

• Amplían los datos. La desconfianza (fallas, riesgos, problemas) aparece más en comentarios que hablan solo de eléctricos (16,3 %) que solo de híbridos (2,7 %); podría ayudar a explicar el predominio de los híbridos, pero es un indicio y no una prueba.

• Brecha de cobertura. La micromovilidad es el 48,6 % de los vehículos eléctricos del RUNT (17.969 de 36.969) pero aparece en solo el 1,1 % de los comentarios; los videos buscados eran sobre carros, así que es un límite de la muestra y no desinterés.

Alcance. Las opiniones corresponden a quienes comentaron en los videos seleccionados; no representan a toda la población. La API no informa el país de quien comenta, así que aun en videos colombianos pueden participar usuarios de otros países.

7. Conclusiones integradas

Respaldado por evidencia

• El tipo de motorización de un grupo de vehículos se deduce principalmente de su clase y carrocería; el departamento y los años aportan poco (ranking de variables y regresión logística).

• Un modelo puede verse bien por grupo y fallar donde está la mayoría de los vehículos: hay que evaluar también ponderando por cantidad.

• Los territorios se separan en tres perfiles (grandes centros, micromovilidad eléctrica e intermedios), con estructura débil a moderada (silueta 0,286). Coincide con el supervisado: la clase del vehículo es lo que más diferencia a eléctricos e híbridos, tanto al predecir como al agrupar.

• En los comentarios, las barreras más citadas son precio, carga y batería; los incentivos se mencionan poco (4,5 %).

• Los datos y los comentarios difieren en lo que cuentan: el RUNT está dominado por híbridos y por micromovilidad eléctrica; la conversación en YouTube, por automóviles eléctricos.

Hipótesis que requieren validación

• El predominio de híbridos en automóviles y camionetas podría deberse a precio, infraestructura de carga o autonomía; el RUNT no trae precio, marca ni puntos de carga, así que no puede probarse con estos datos.

• La mayor desconfianza hacia los eléctricos en los comentarios podría explicar parte de la preferencia por híbridos; son pocos comentarios de híbridos y no se sabe quién los escribe.

• Las ciudades intermedias podrían seguir la trayectoria de los grandes centros; requiere datos de varios años por territorio y de población.

Decisiones que podrían apoyarse. Priorizar infraestructura de carga según el perfil del territorio; tratar la micromovilidad eléctrica con una política distinta a la de automóviles y camionetas; y complementar el RUNT con datos de precios, marcas y puntos de carga antes de medir causas.

8. Limitaciones generales

• El conjunto es agregado: no hay vehículos únicos, placa, marca, precio, población ni puntos de carga; no se pueden calcular tasas per cápita ni causas.

• Validación del supervisado optimista por combinaciones repetidas; estructura de clustering débil a moderada; LDA con coherencia moderada y azar entre ejecuciones.

• Los comentarios son una muestra autoseleccionada, no aleatoria (orden por relevancia, tope de 500 por video, videos buscados mayormente sobre carros); la codificación por diccionario es aproximada y no mide sentimiento.

9. Referencias

Los enlaces de acceso al repositorio, a la aplicación publicada y al video de sustentación están en la tabla «Recursos», al final de este documento.

Los flujos de Orange se describen en la sección 3. Los scripts (preparación, modelos, clustering, extracción, limpieza y análisis de texto), los resultados en JSON y los metadatos de los videos están en el repositorio; los comentarios y la clave de la API no se publican.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet allocation. Journal of Machine Learning Research, 3, 993–1022.

Datos Abiertos Colombia. (2026). Vehículos eléctricos e híbridos matriculados en Colombia - RUNT 2.0 [Conjunto de datos]. https://www.datos.gov.co/Transporte/VEH-CULOS-EL-CTRICOS-E-H-BRIDOS-MATRICULADOS-EN-CO/ntxy-q9ix/about_data

Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinovič, M., Možina, M., Polajnar, M., Toplak, M., Starič, A., Štajdohar, M., Umek, L., Žagar, L., Žbontar, J., Žitnik, M., & Zupan, B. (2013). Orange: Data mining toolbox in Python. Journal of Machine Learning Research, 14, 2349–2353.

Google. (s. f.). YouTube Data API v3. https://developers.google.com/youtube/v3

Porter, M. F. (2001). Snowball: A language for stemming algorithms. http://snowball.tartarus.org/texts/introduction.html

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.

Recursos

Recurso	URL
Conjunto de datos	datos.gov.co · ntxy-q9ix
Repositorio	github.com/Lando18tinez/MINERIA_AJ
Aplicación publicada	mineria-aj.onrender.com