

UDEC
UNIVERSIDAD DE
CUNDINAMARCA

Etapa 6 Conocimiento Oculto

Angelica Rosa Olier Quiroga

Johan Orlando Martinez Suarez

Programa de Ingeniería de Sistemas y Computación

Universidad de Cundinamarca

Minería de Datos

Ingeniero Edison Gustavo Cañón Varela

Noviembre 2026

Etapa 6 - Construcción de los flujos en Orange Data Mining

Se construyeron en Orange Data Mining 3.40 (con el complemento Text) los tres flujos de la Etapa 6. La mayoría de las cifras coincide con las de los scripts del repositorio (archivos resultados_etapa6_*.json): la regresión logística logra AUC 0,941 y accuracy 0,870; el clustering forma 3 grupos de 22, 34 y 42 territorios, y el corpus de comentarios deja un vocabulario de 1.690 términos.

Los flujos se guardaron en una carpeta local (fuera del repositorio) como `01_supervisado.ows, 02_clustering.ows y 03_comentarios_youtube.ows`. Cada apartado describe la configuración de cada widget y muestra su captura de pantalla.

Flujo	Archivo	Pregunta
1 · Supervisado	01_supervisado.ows	¿Un grupo de vehículos es eléctrico o híbrido?
2 · Clustering	02_clustering.ows	¿Qué perfiles de territorio existen?
3 · Comentarios	03_comentarios_youtube.ows	¿De qué hablan los comentarios de YouTube?

El dataset es agregado: cada fila es un grupo de vehículos y la columna `cantidad` indica cuántos son. Por eso `cantidad` se usa como peso (meta) y nunca como predictora.

Flujo 1 - Supervisado: preparación de datos

La preparación deja 6.768 grupos de vehículos con 6 predictoras, la clase `tipo_motorizacion` y `cantidad` como peso. La Figura 1 muestra el flujo completo.

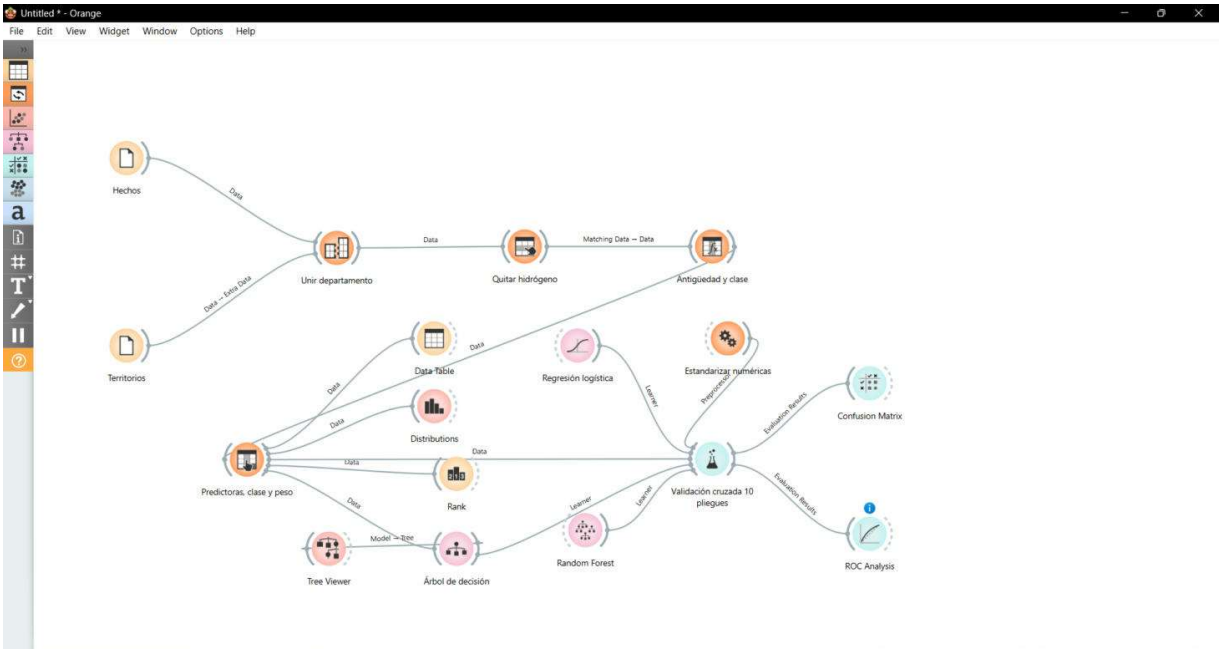


Figura 1. *Lienzo del flujo 01_supervisado.ows.*

File «Hechos». Carga `data\powerbi\hechos_vehiculos.csv`: 6.772 filas, 8 variables y `territorio` como meta de texto.

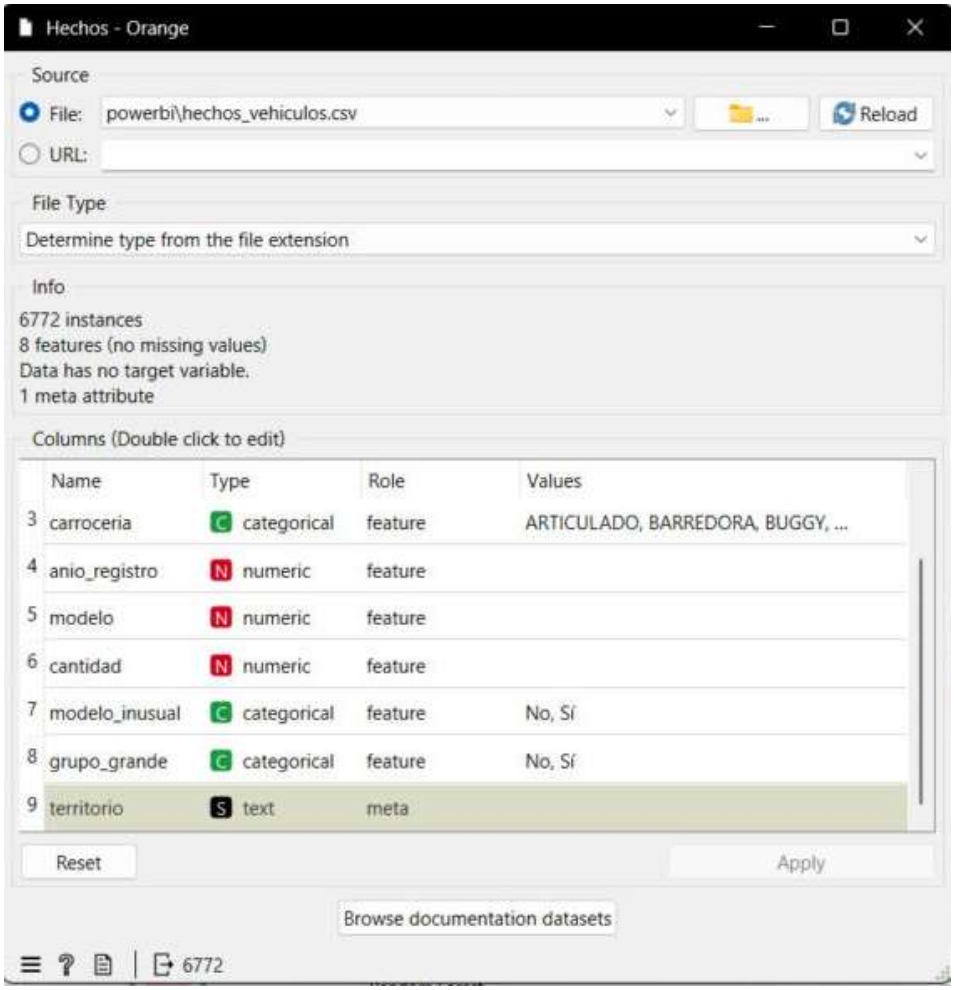


Figura 2. *Widget File «Hechos».*

File «Territorios». Carga `data\powerbi\dim_territorio.csv`: 247 filas, `departamento` categórica y `territorio` y `municipio` como metas.

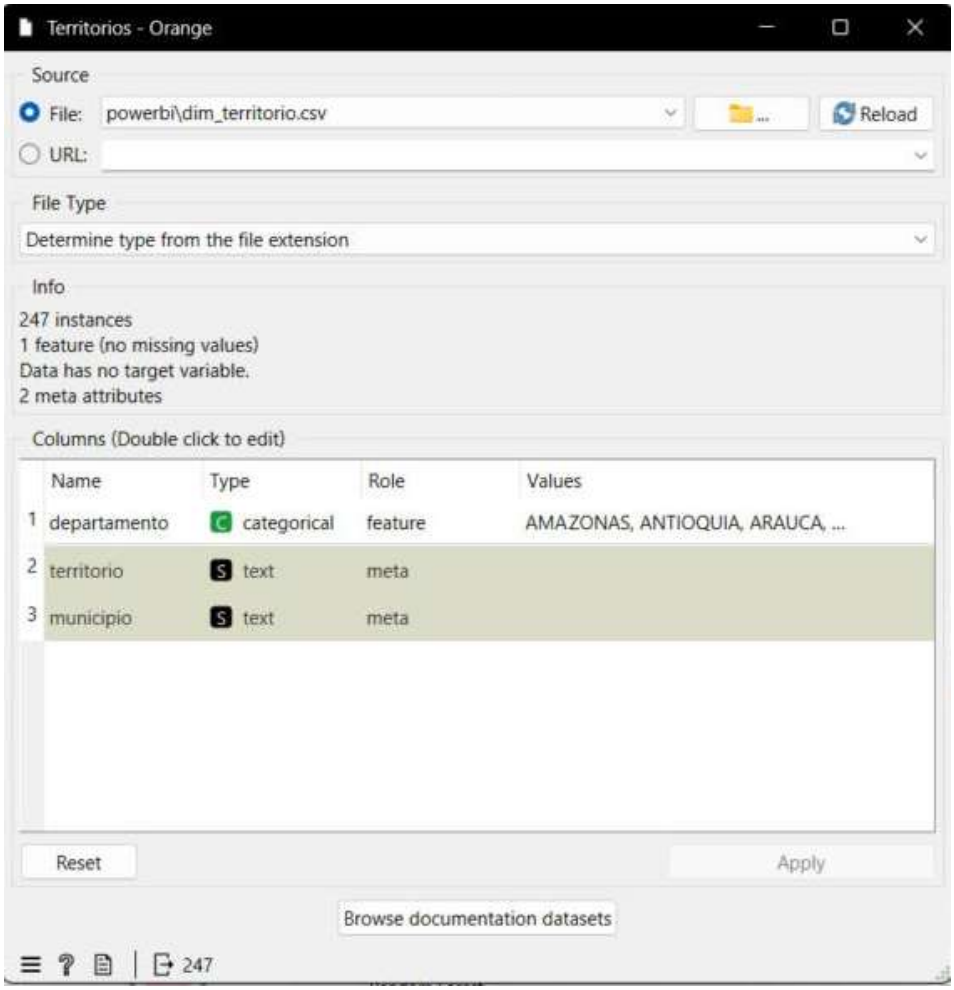


Figura 3. *Widget File «Territorios».*

Merge Data «Unir departamento». Modo «Append columns from Extra data», uniendo `territorio` = `territorio`. Salida: 6.772 filas con `departamento`.

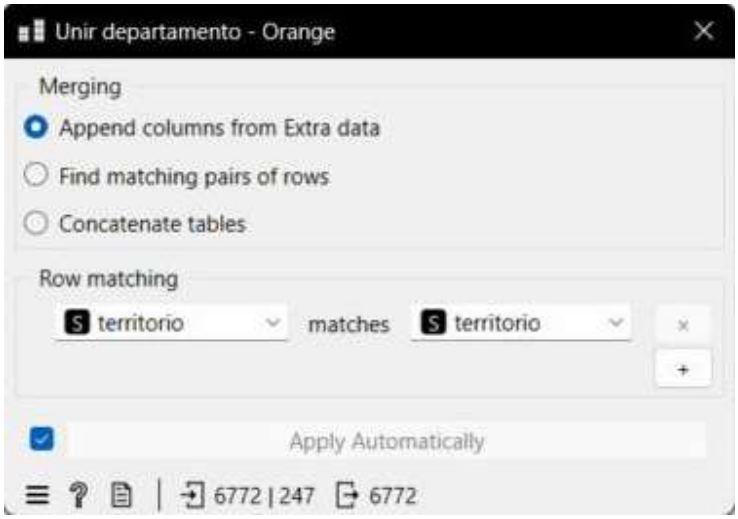


Figura 4. *Widget Merge Data.*

Select Rows «Quitar hidrógeno». Condición `combustible` is not `HIDROGENO`. Salida «Matching Data»: 6.768 filas (salen 4 grupos).

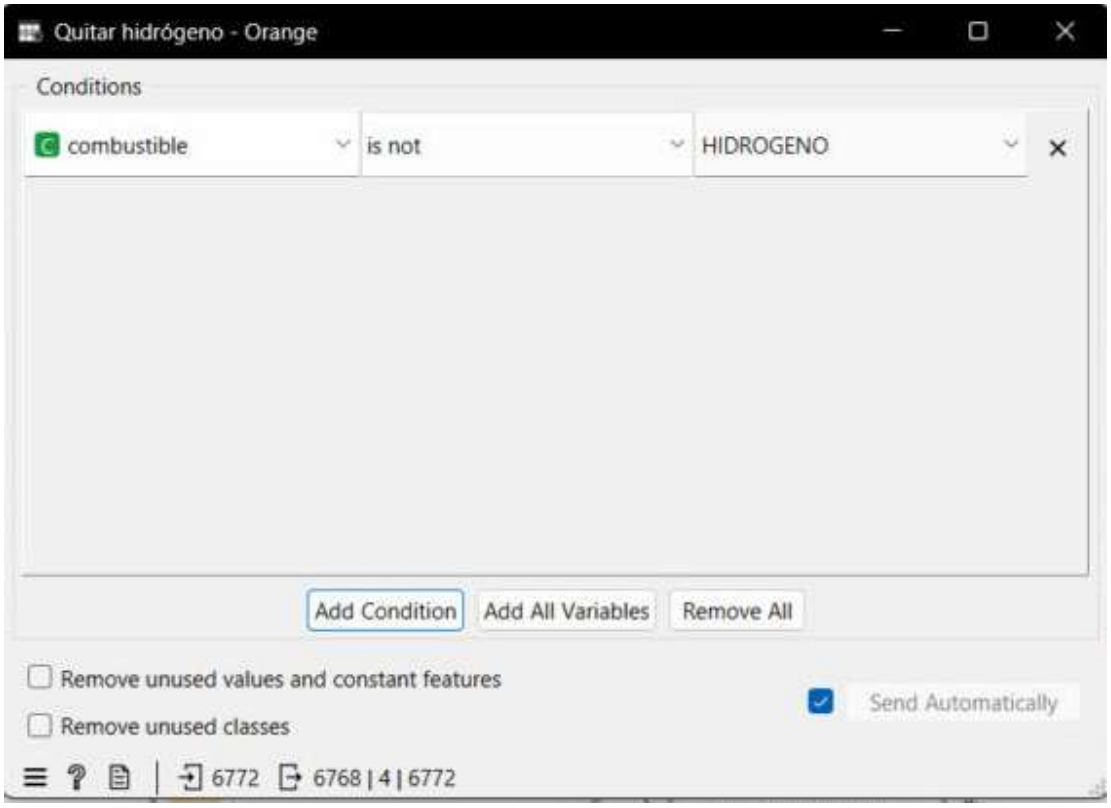


Figura 5. *Widget Select Rows.*

Formula «Antigüedad y clase». Crea dos variables:

- `antiguedad_modelo` (numérica) = `anio_registro - modelo`.
- `tipo_motorizacion` (categórica, valores ELECTRICO, HIBRIDO) = `0 if combustible == 'ELECTRICO' else 1`.

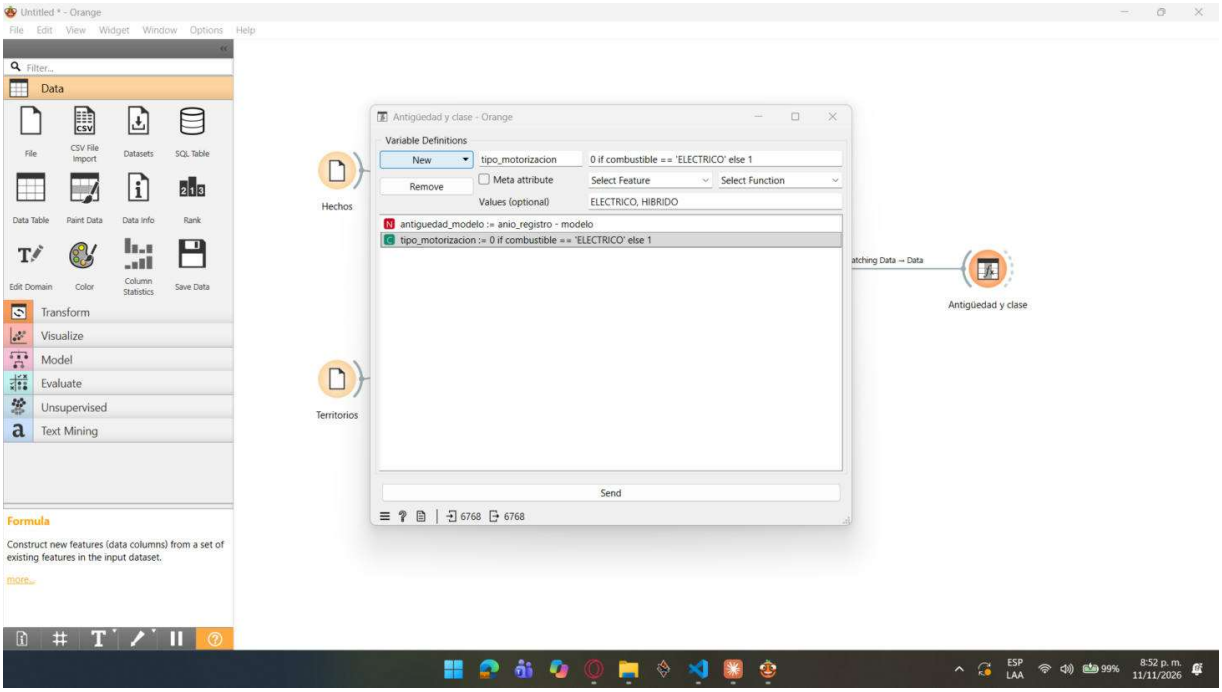


Figura 6. *Widget Formula con las dos variables nuevas.*

Select Columns «Predictoras, clase y peso». Features: `clase`, `carroceria`, `departamento`, `anio_registro`, `modelo`, `antiguedad_modelo`. Target: `tipo_motorizacion`. Meta: `cantidad`. Ignoradas: `combustible` (evita fuga de información), `modelo_inusual`, `grupo_grande`, `territorio` y `municipio`.

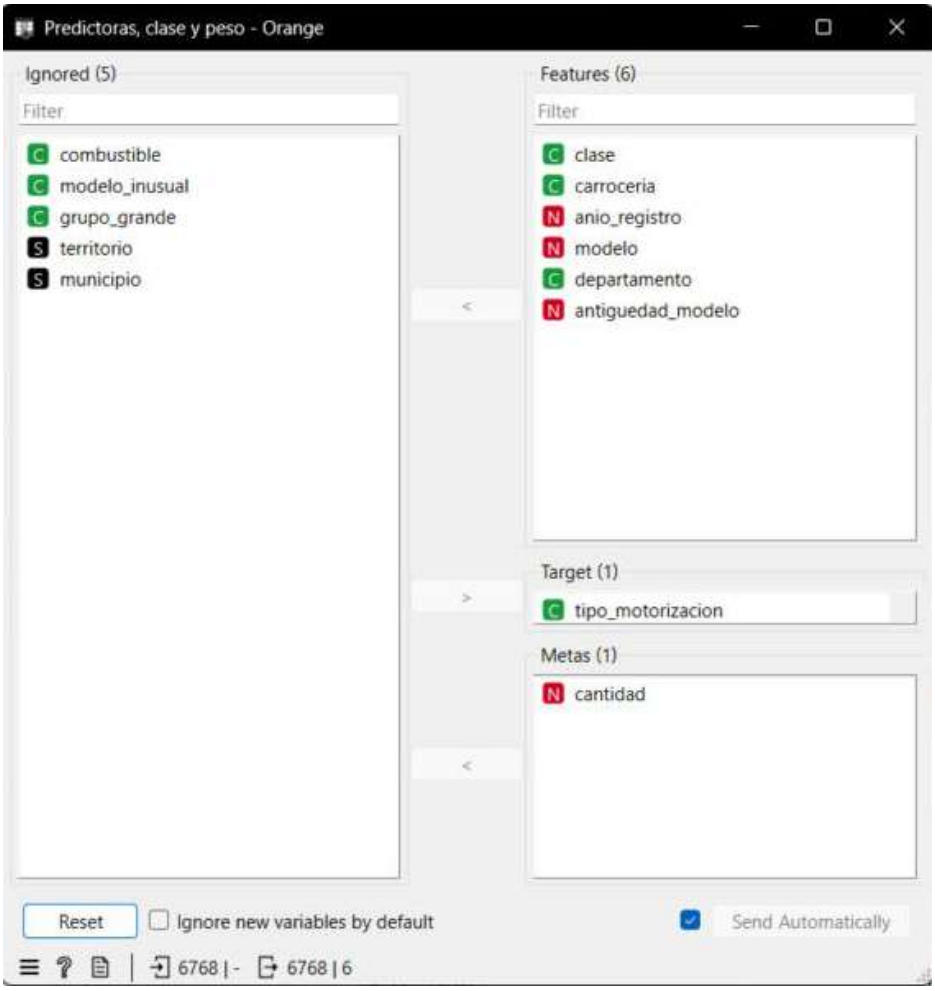


Figura 7. *Widget Select Columns.*

Flujo 1 - Modelos y evaluación

La regresión logística es el mejor modelo (AUC 0,941; CA 0,870), por delante de Random Forest (0,933) y el árbol (0,904). Los tres se evalúan con las mismas condiciones: validación cruzada estratificada de 10 pliegues y clase objetivo ELECTRICO.

Exploración. Distributions sobre `tipo_motorizacion` muestra 3.583 grupos ELECTRICO (52,9 %) y 3.185 HIBRIDO. Rank (ganancia de información) ubica `carroceria` (0,554) y `clase` (0,468) arriba; el resto queda por debajo de 0,07.



Figura 8. *Distributions de tipo_motorizacion.*

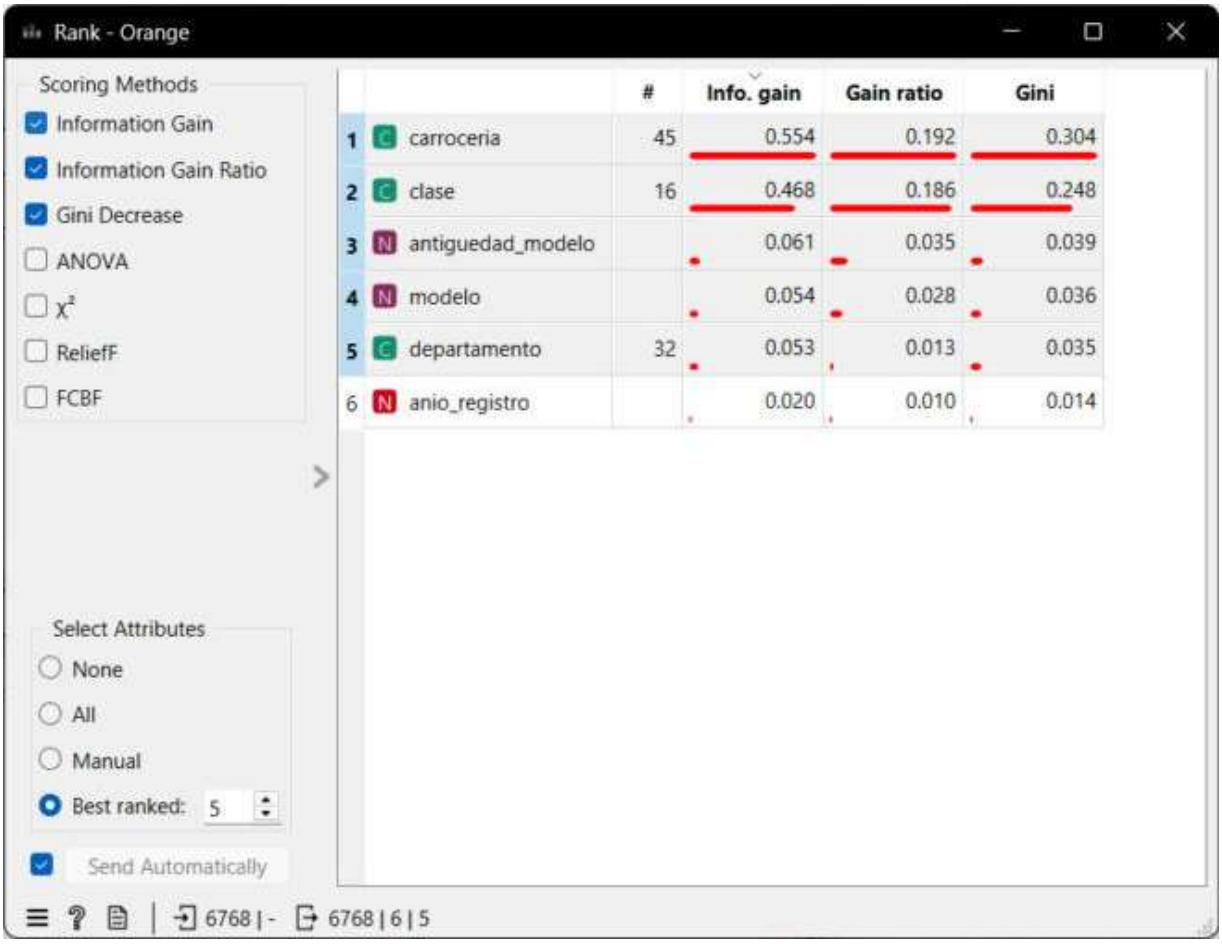


Figura 9. *Rank de variables.*

Preprocess «Estandarizar numéricas». Un solo paso: Normalize Features → Standardize to $\mu=0$, $\sigma^2=1$. Su salida «Preprocessor» entra en Test and Score.

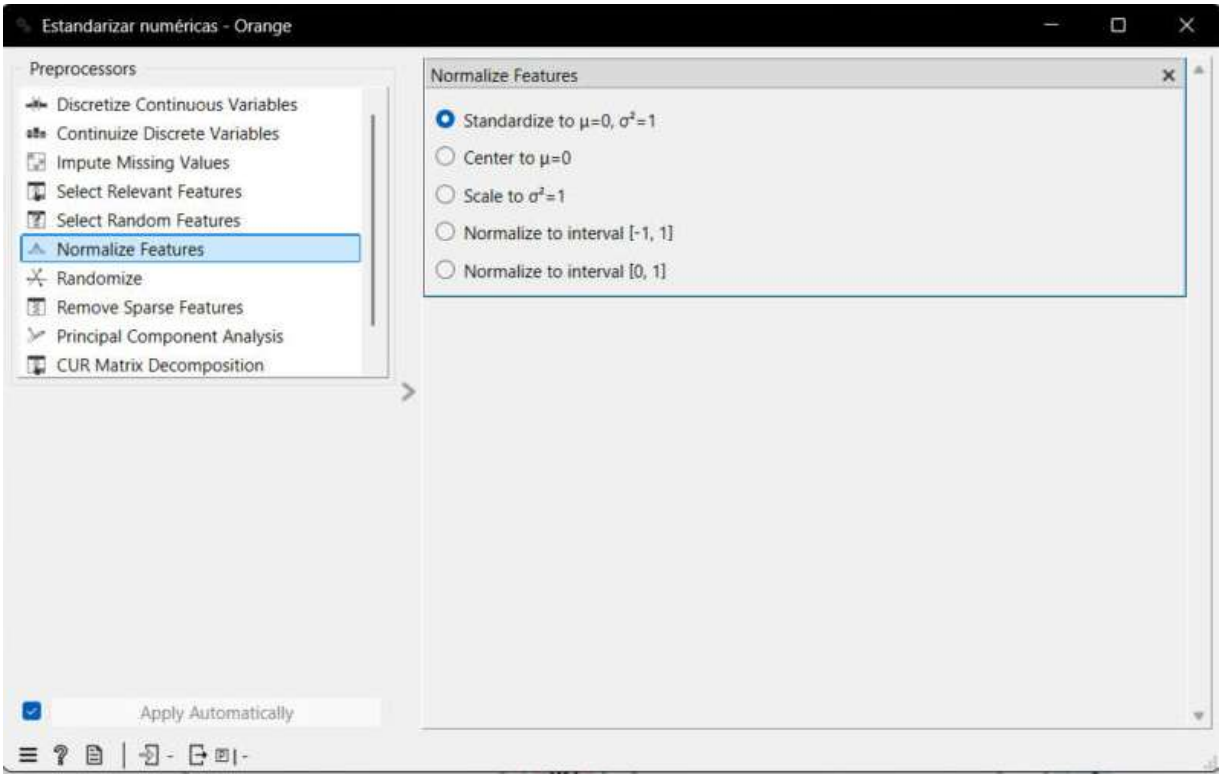


Figura 10. *Widget Preprocess.*

Logistic Regression. Regularización Ridge (L2), C = 1, sin balanceo de clases.

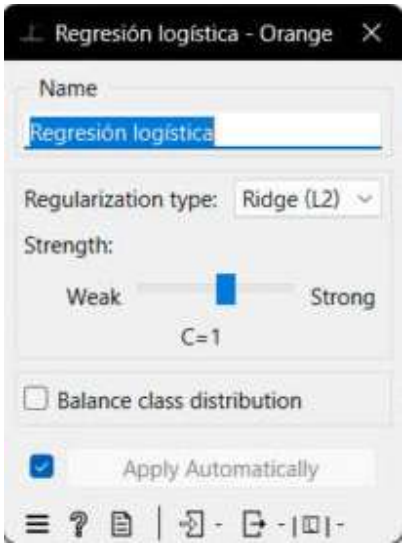


Figura 11. *Widget Logistic Regression.*

Tree «Árbol de decisión». «Induce binary tree» desmarcado; mínimo 2 instancias por hoja; no dividir subconjuntos menores de 5; profundidad máxima 100; parar cuando la mayoría alcanza 95 %.

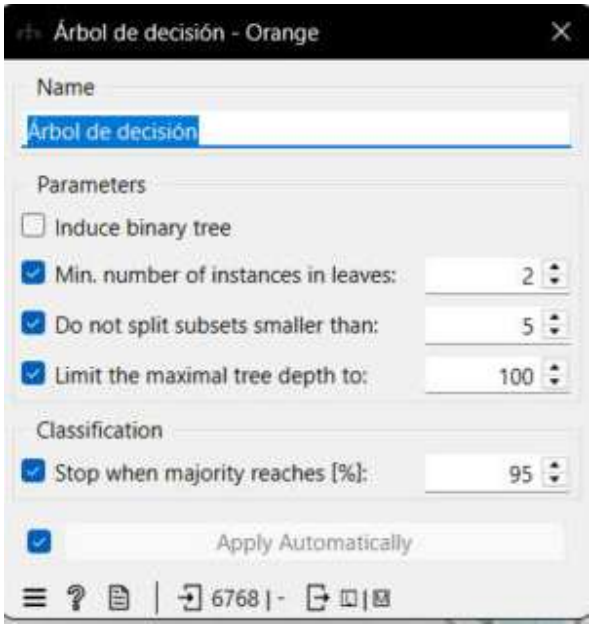


Figura 12. *Widget Tree.*

Random Forest. 100 árboles, no dividir subconjuntos menores de 5, «Replicable training» marcado, sin límite de profundidad ni de atributos.

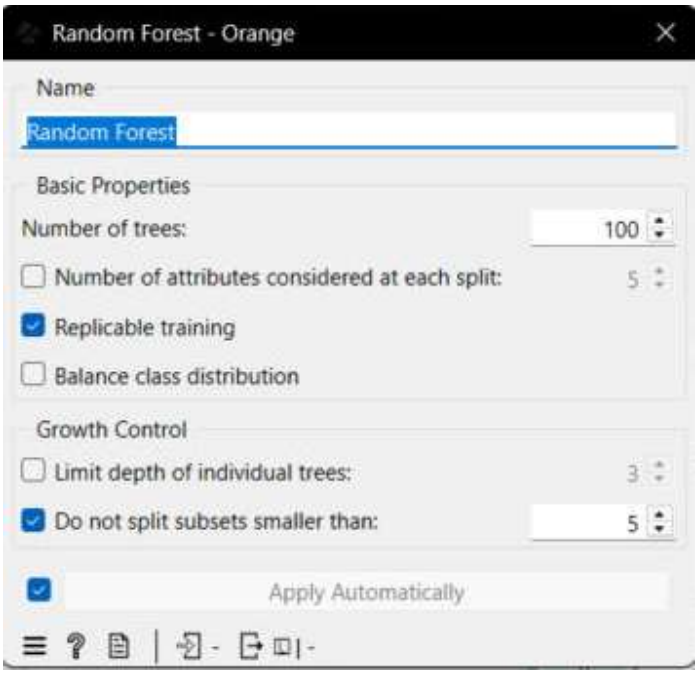


Figura 13. *Widget Random Forest.*

Test and Score «Validación cruzada 10 pliegues». Entradas: Data desde Select Columns, los 3 aprendices y el Preprocessor. Cross validation, 10 folds, Stratified; Target class = ELECTRICO.

Modelo	AUC	CA	F1	Precisión	Recall
Regresión logística	0,941	0,870	0,868	0,944	0,802
Random Forest	0,933	0,868	0,869	0,916	0,827
Árbol de decisión	0,904	0,845	0,850	0,871	0,829

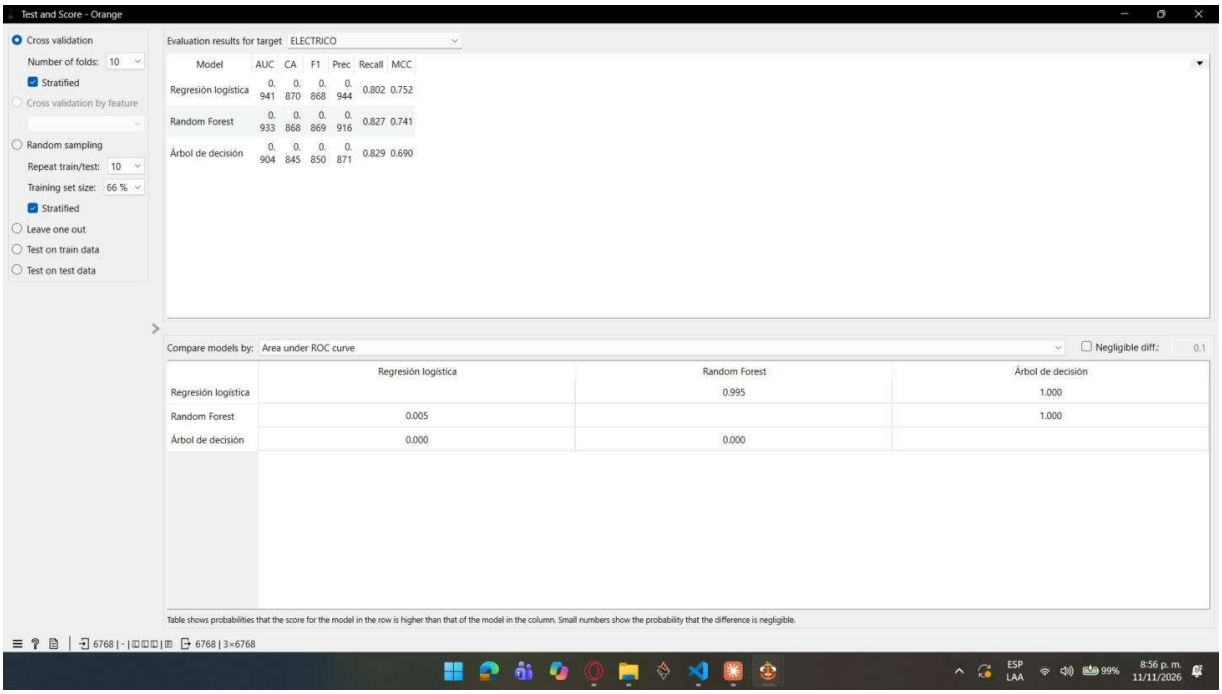


Figura 14. *Test and Score con los tres modelos.*

Confusion Matrix y ROC Analysis. Conectados a «Evaluation Results». La regresión logística acierta 2.875 eléctricos y 3.015 híbridos; clasifica 708 eléctricos como híbridos y 170 híbridos como eléctricos.

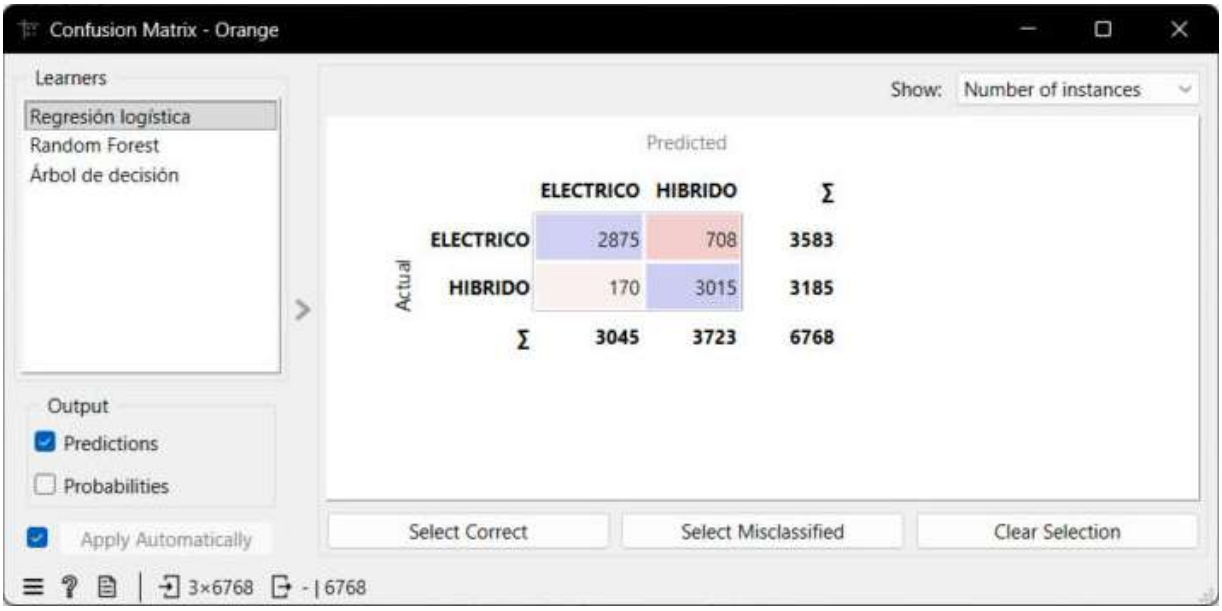


Figura 15. *Matriz de confusión de la regresión logística.*

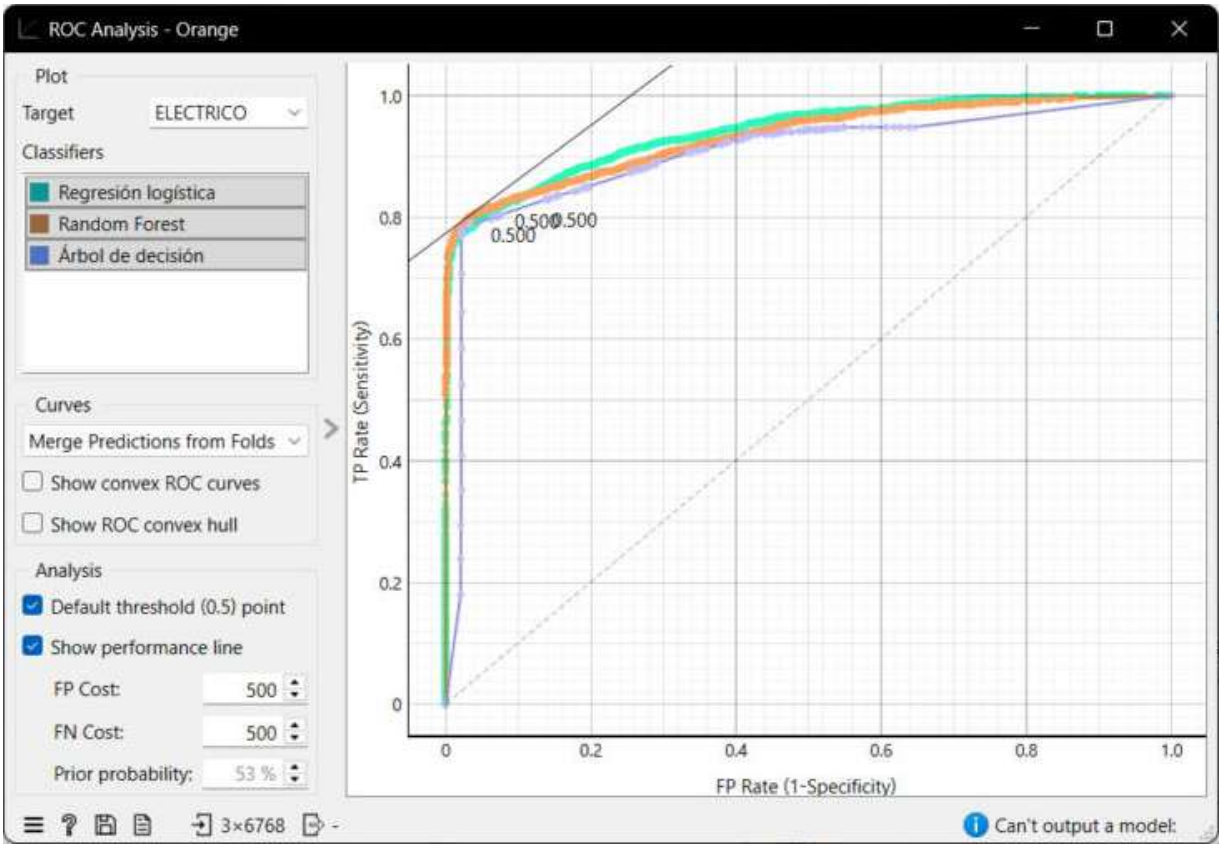


Figura 16. *Curvas ROC de los tres modelos.*

Tree Viewer. Recibe el «Model» del árbol: 972 nodos y 561 hojas según Orange (el script etapa6_modelos.py cuenta 973 y 562 sobre el mismo árbol; la diferencia de una unidad no se investigó), con `carroceria` en la raíz.

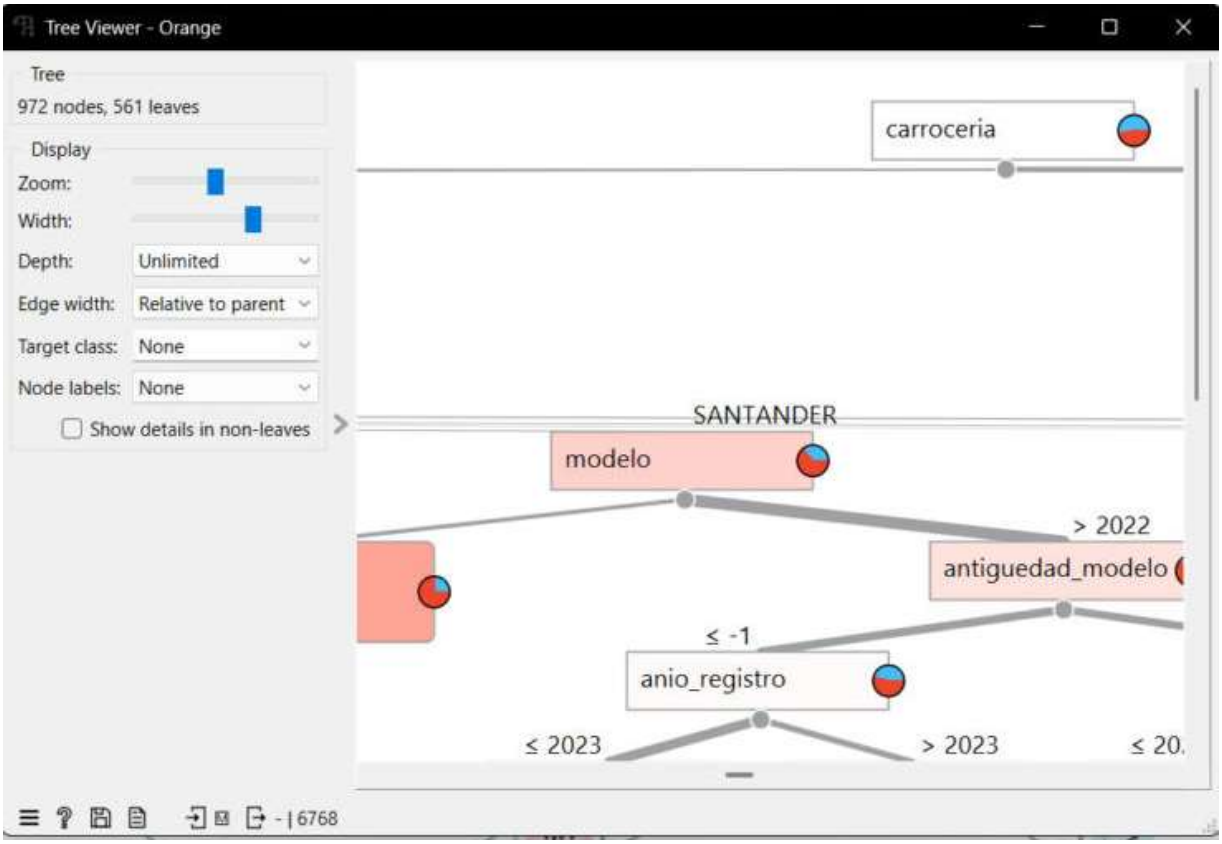


Figura 17. *Tree Viewer.*

Flujo 2 - Clustering: preparación de datos

La preparación convierte los 6.772 grupos en 98 territorios con al menos 30 vehículos, descritos por 8 variables. No se usan `combustible` ni `tipo_motorizacion` para formar los grupos. Los widgets File ×2 y Merge Data se copiaron del flujo 1 con la misma configuración.

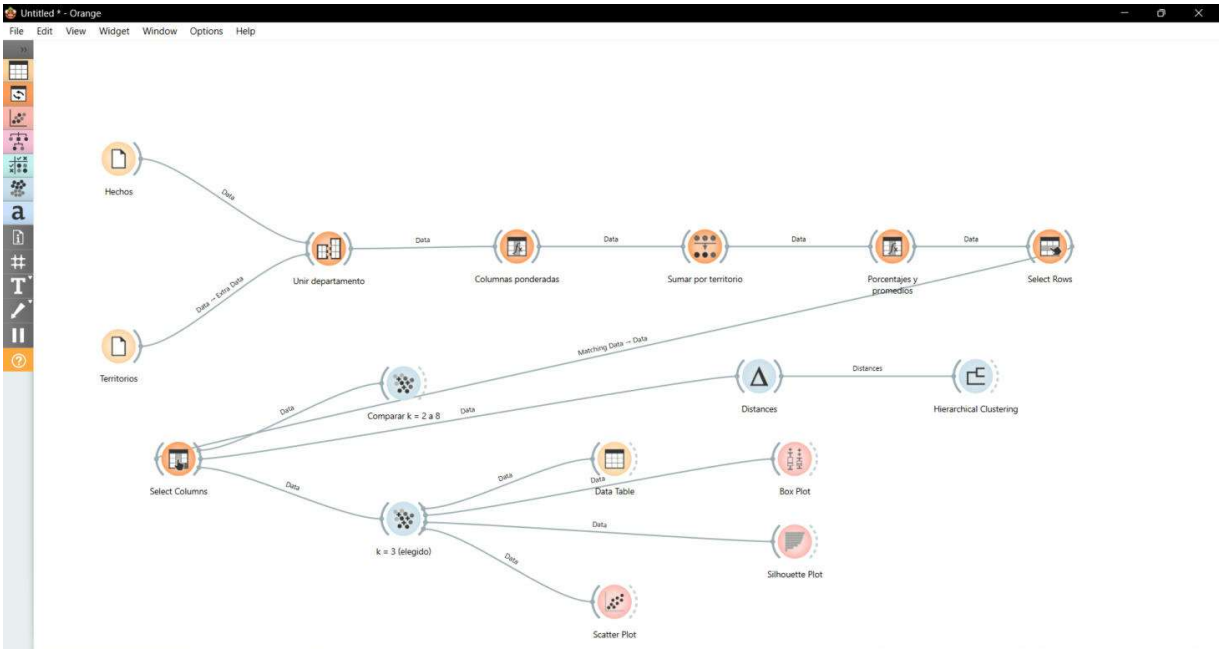


Figura 18. *Lienzo del flujo 02_clustering.ows.*

Formula «Columnas ponderadas». Siete columnas multiplicadas por `cantidad`, para sumar vehículos y no filas:

- `w_cam, w_aut, w_cmp = cantidad * (clase == 'CAMIONETA' | 'AUTOMOVIL' | 'CAMPERO').`
- `w_mic = cantidad * (clase in (CICLOMOTOR, CUADRICICLO, CUATRIMOTO, MOTOCARRO, MOTOCICLETA, MOTOTRICICLO, TRICIMOTO)).`
- `w_rec = cantidad * (anio_registro >= 2022).`
- `w_anio = cantidad * anio_registro; w_antig = cantidad * (anio_registro - modelo).`

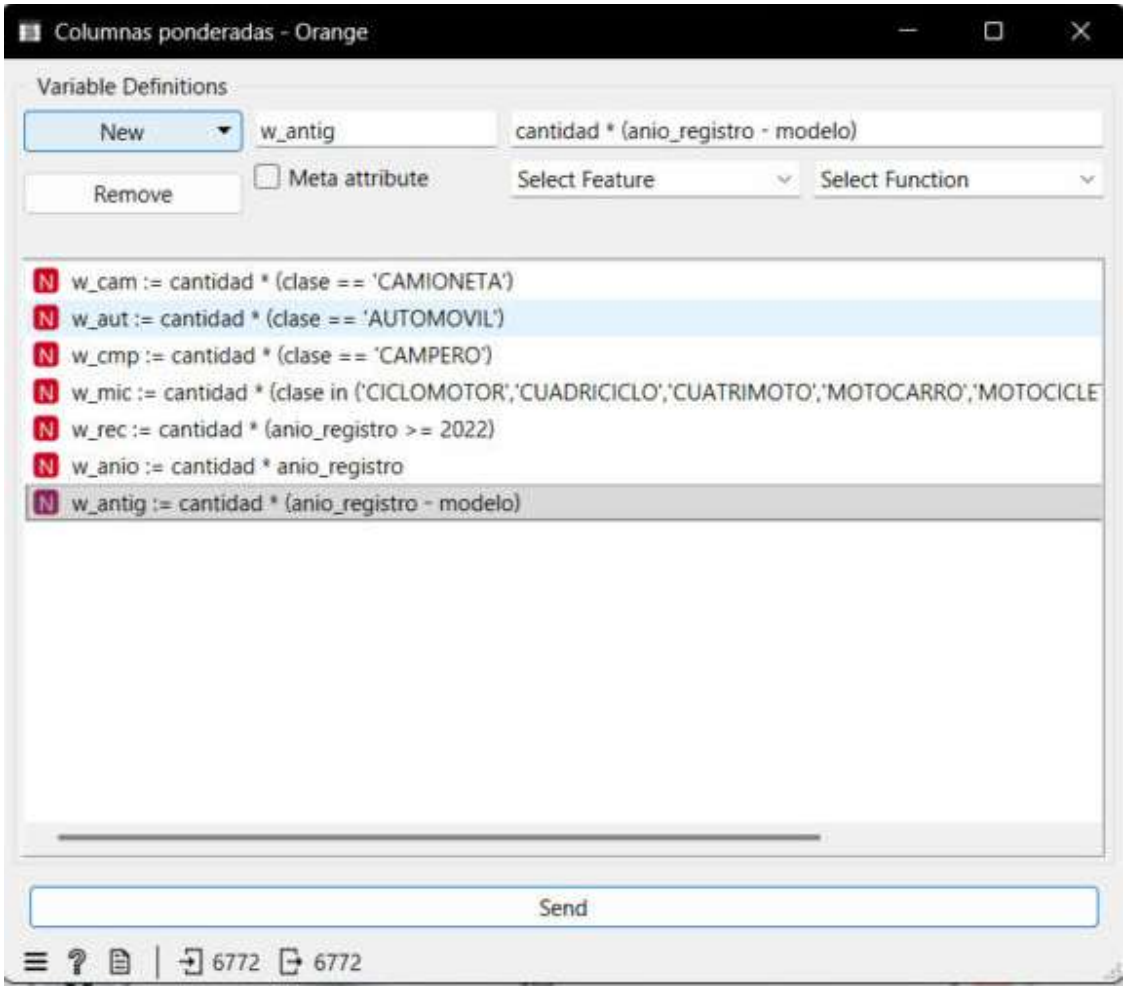


Figura 19. *Formula «Columnas ponderadas».*

Group by «Sumar por territorio». Agrupa por `territorio` y aplica solo Sum a `cantidad` y a las siete `w_*`; el resto de variables queda sin agregación. Salida: 247 filas.

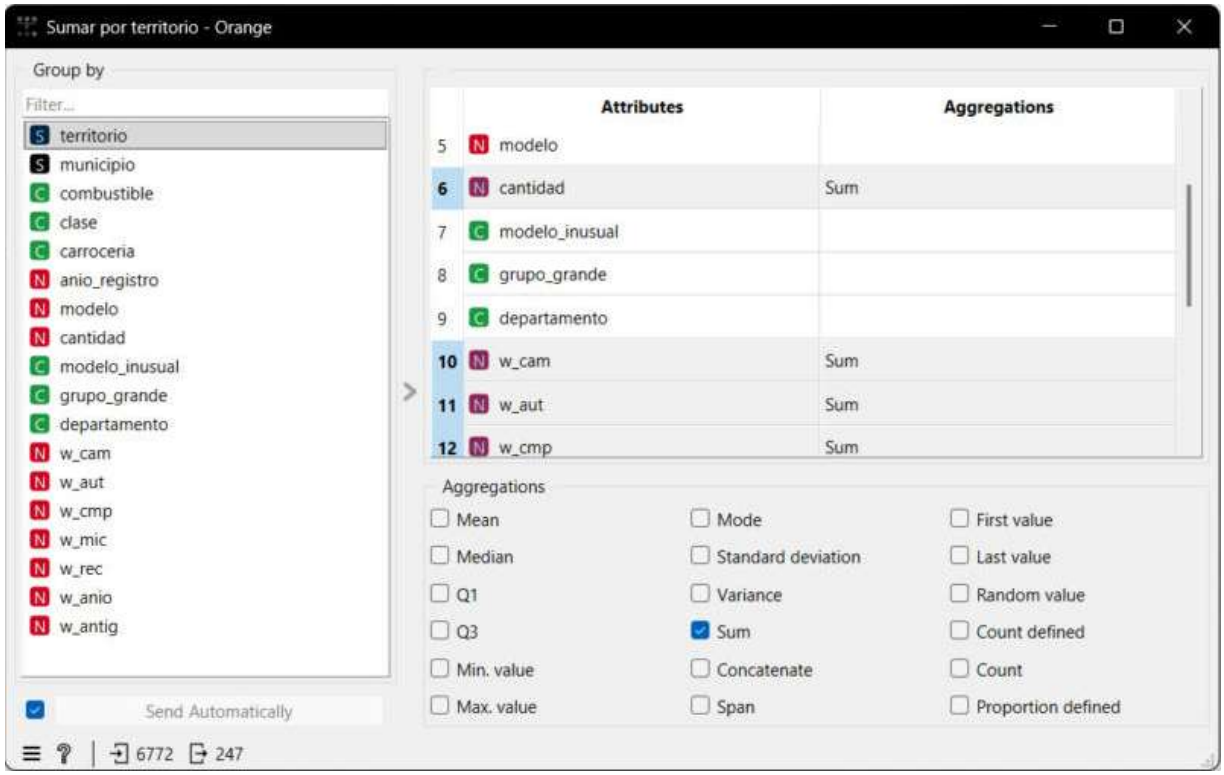


Figura 20. *Group by con las agregaciones Sum.*

Formula «Porcentajes y promedios». Nueve variables a partir de las sumas (Orange nombra «cantidad - Sum» como `cantidad___Sum`): `vehiculos`, `log10_vehiculos`, `pct_camioneta`, `pct_automovil`, `pct_campero`, `pct_micromovilidad`, `pct_registro_2022_2024`, `anio_registro_medio` y `antiguedad_media`.

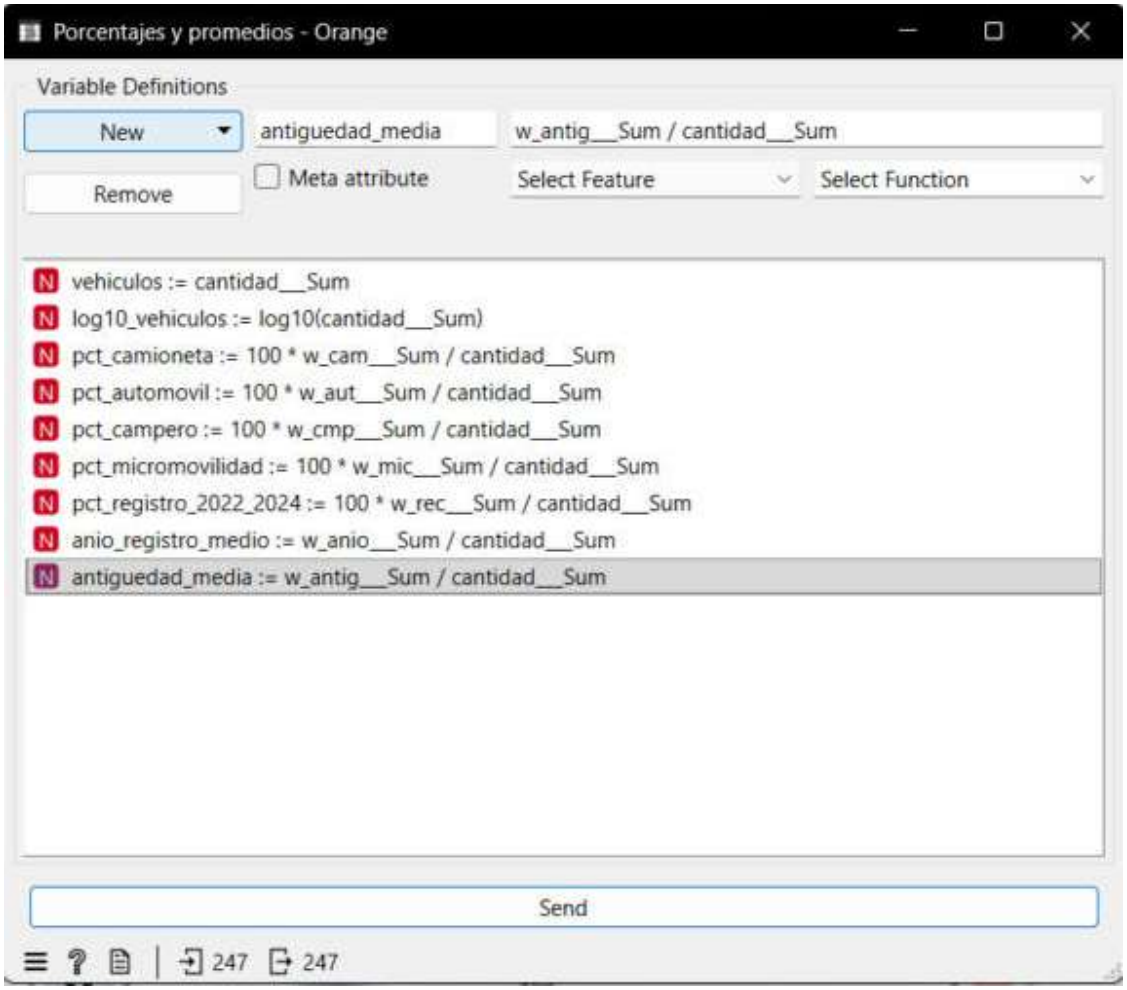


Figura 21. *Formula «Porcentajes y promedios».*

Select Rows. Condición `vehiculos` is at least 30. Quedan 98 territorios; los otros 149 tienen menos de 30 vehículos y darían porcentajes inestables.

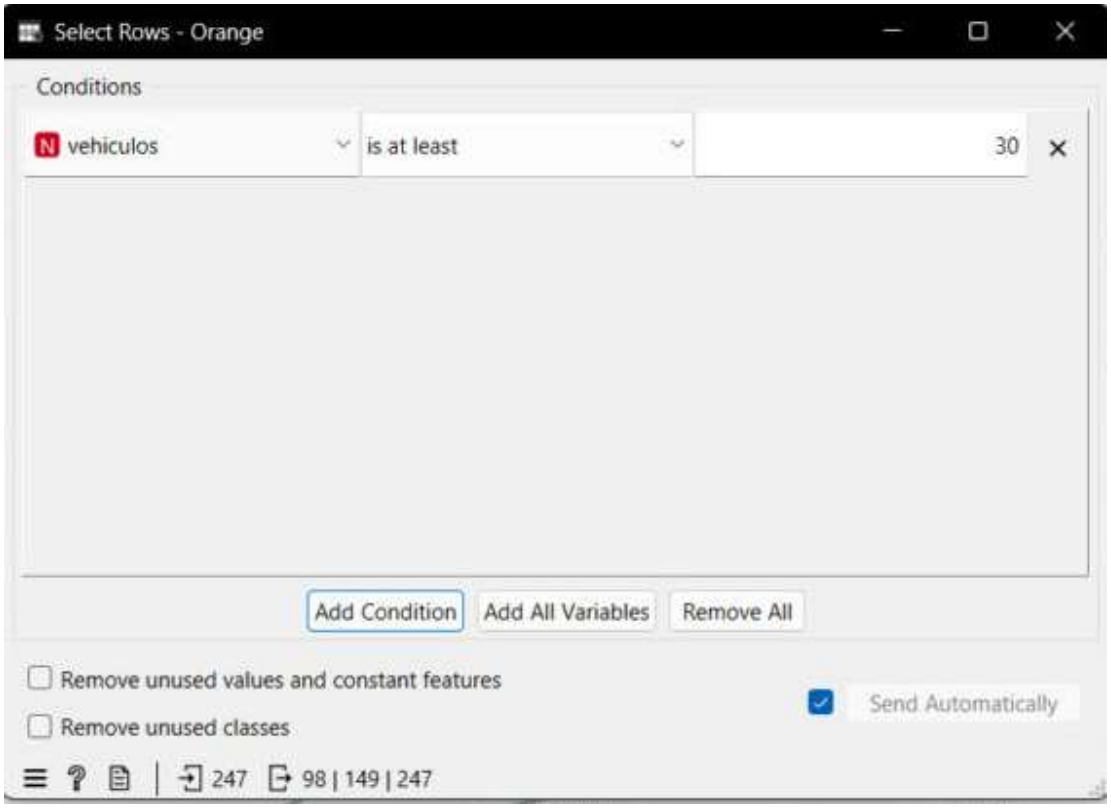


Figura 22. *Select Rows (vehiculos ≥ 30).*

Select Columns. Features: las 8 variables de perfil (`log10_vehiculos`, cuatro porcentajes de clase, `pct_registro_2022_2024`, `anio_registro_medio` y `antiguedad_media`). Metas: `territorio` y `vehiculos`. Sin target; las sumas quedan ignoradas.

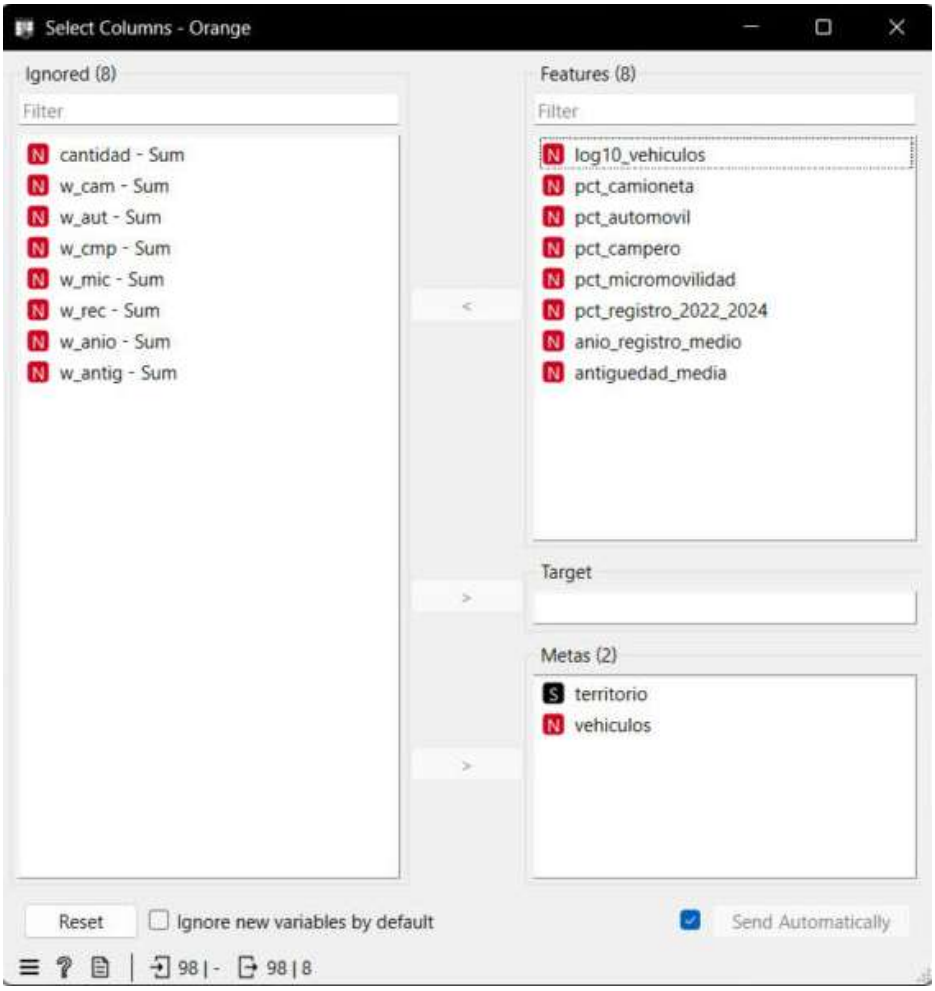


Figura 23. *Select Columns del flujo 2.*

Flujo 2 - Agrupamiento y visualización

Se eligió k = 3, que forma grupos de 22, 34 y 42 territorios. k = 2 tiene la silueta más alta (0,452), pero solo separa los territorios de micromovilidad (36) del resto (62), algo que ya se ve en los datos; k = 3 (0,286) conserva ese grupo, divide el resto en grandes centros y ciudades intermedias y es la mejor silueta entre los k ≥ 3. Es una elección de interpretabilidad: ambas siluetas indican una estructura débil a moderada.

k-Means «Comparar k = 2 a 8». «Optimize the number of clusters» de 2 a 8, Normalize columns marcado, inicialización KMeans++, 10 re-ejecuciones y 300 iteraciones máximas. Normalizar es obligatorio porque las variables tienen escalas muy distintas (porcentajes 0–100, años ≈ 2020, logaritmos 1–5).

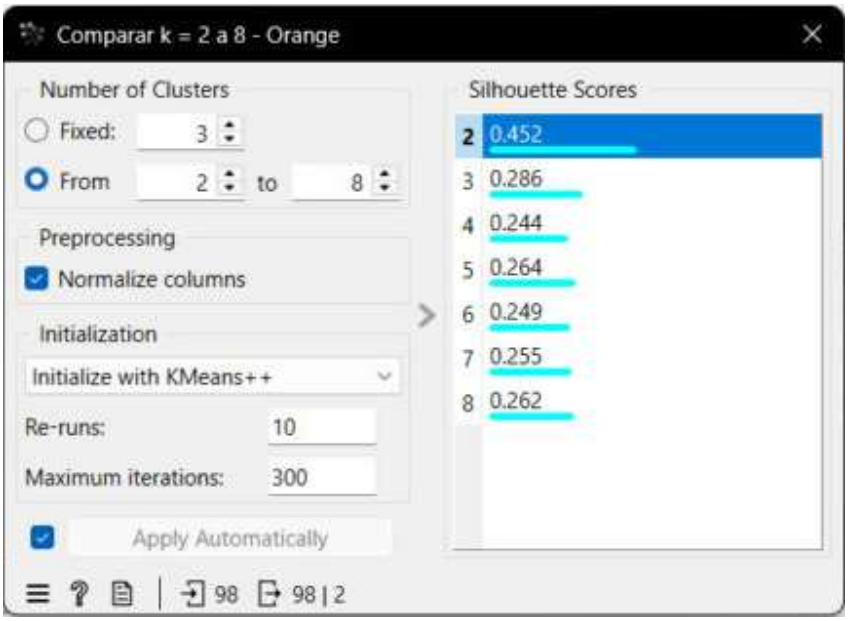


Figura 24. *Silueta media para k = 2 a 8.*

k-Means «k = 3 (elegido)». k fijo = 3 con las mismas opciones. Su salida «Data» alimenta Data Table, Scatter Plot, Box Plot y Silhouette Plot.

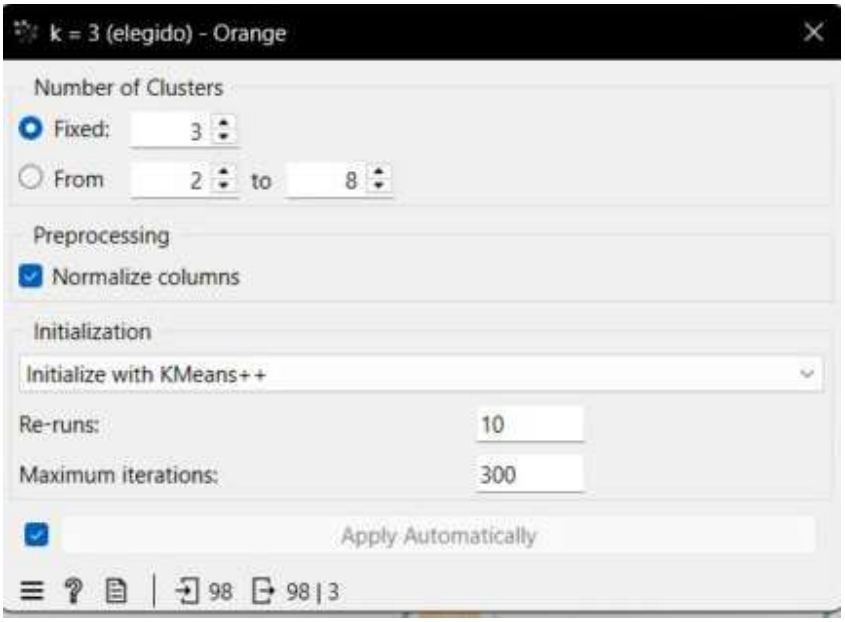


Figura 25. *k-Means con k = 3.*

Grupo	Territorios	Perfil
C1	22	Ciudades grandes (Bogotá, Medellín, Cali…); según resultados_etapa6_clustering.json reúnen ≈ 86,9 % de los

Grupo	Territorios	Perfil
		vehículos
C2	34	Micromovilidad, media de 83,6 % (Madrid, Cartagena, Soacha…)
C3	42	Ciudades intermedias con camionetas (Girón, Pasto, Neiva…)

Scatter Plot. Eje x `log10_vehiculos`, eje y `pct_camioneta`, color por `Cluster`: los tres grupos se separan con claridad.

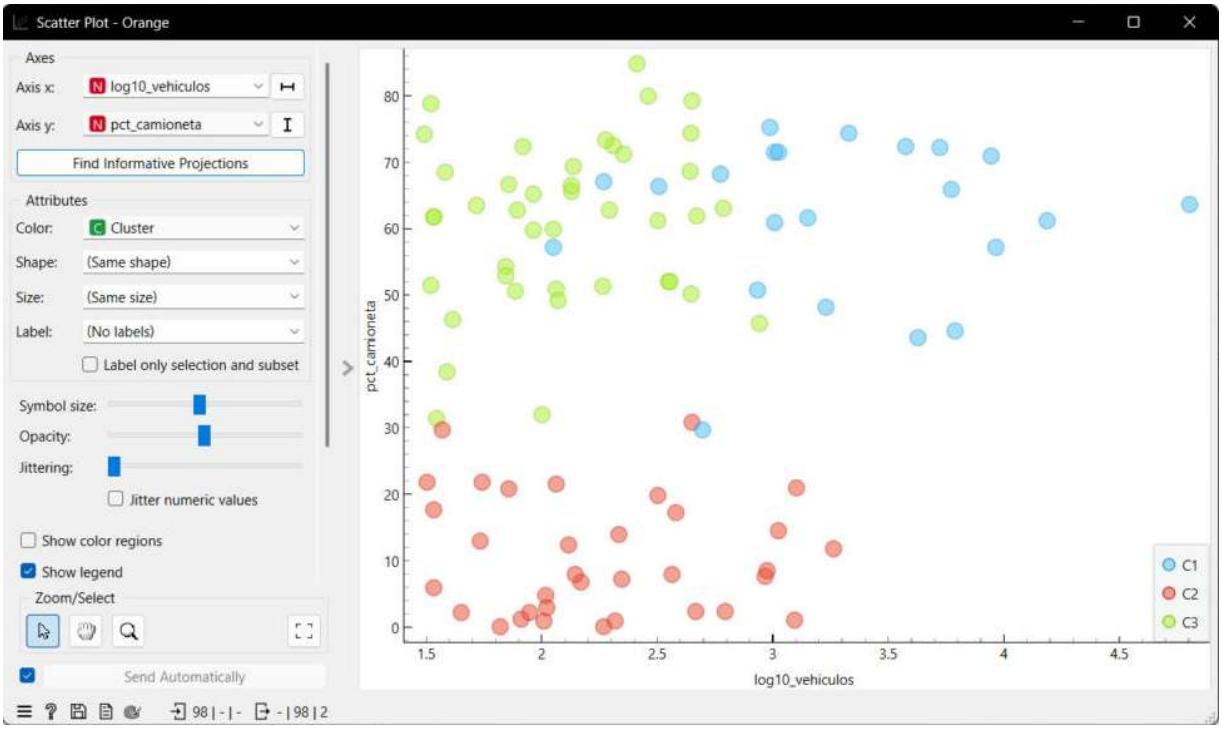


Figura 26. *Scatter Plot coloreado por Cluster.*

Box Plot. Variable `pct_micromovilidad` con subgrupos por `Cluster`. ANOVA = 224,0 ($p < 0{,}001$).

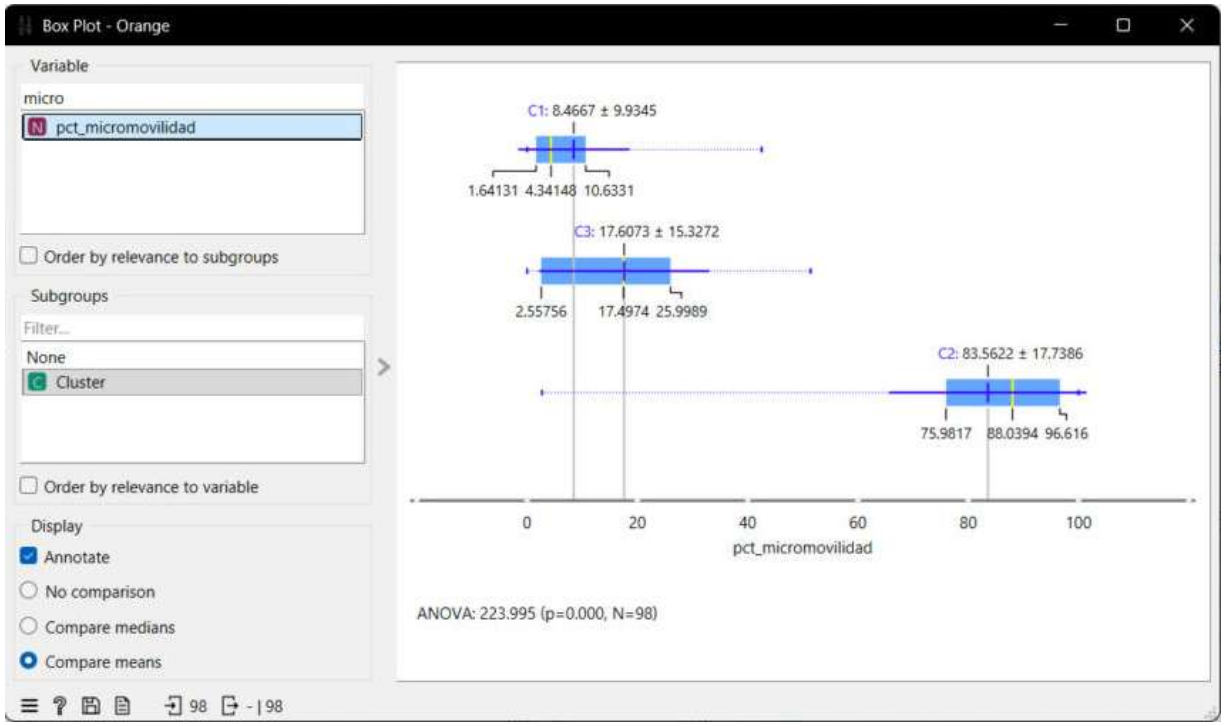


Figura 27. *Box Plot de pct_micromovilidad por grupo.*

Distances → Hierarchical Clustering. Desde Select Columns, distancia Euclidean (normalized) y enlace Ward, como comprobación del agrupamiento.

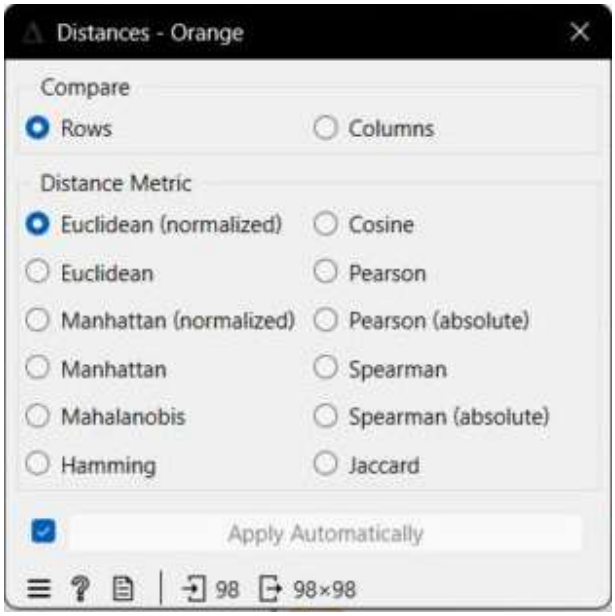


Figura 28. *Widget Distances (euclidiana normalizada).*

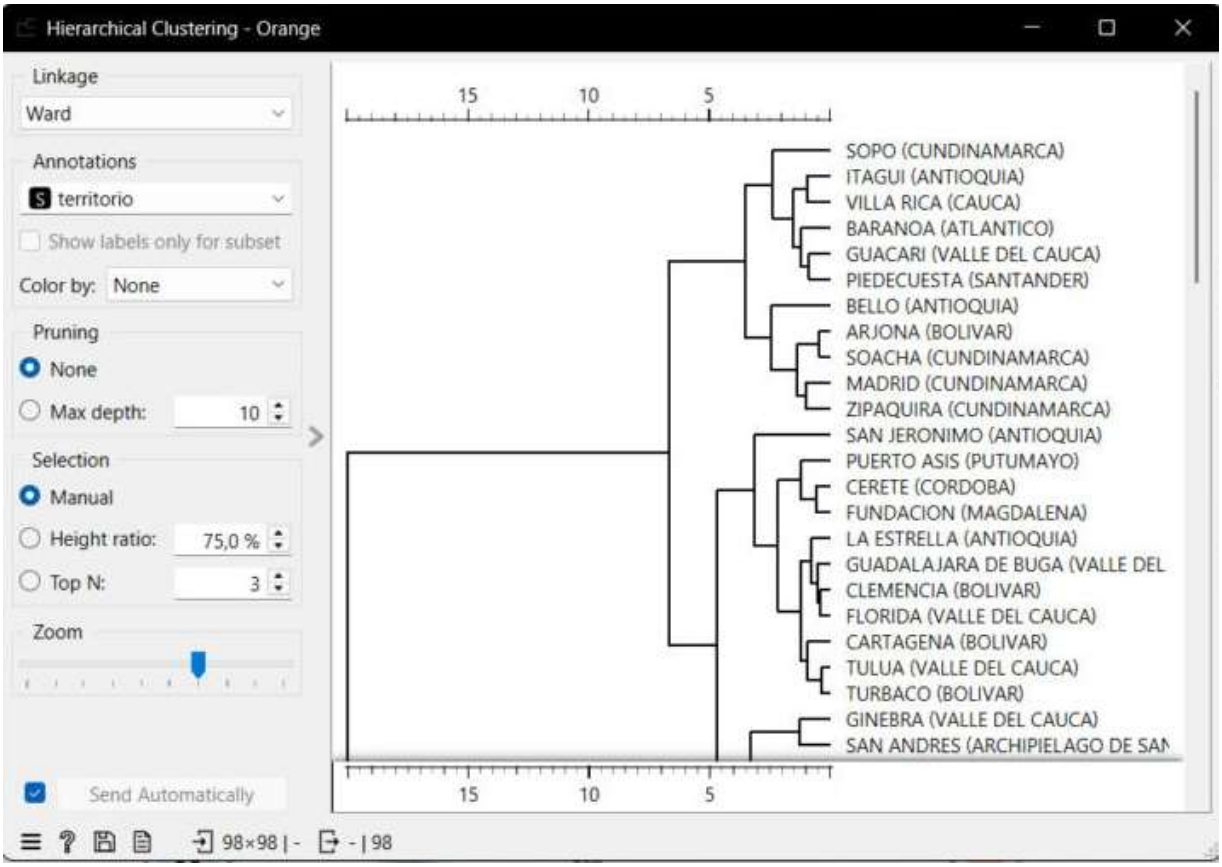


Figura 29. *Dendrograma con enlace Ward.*

Flujo 3 - Comentarios de YouTube

El corpus tiene 2.657 comentarios y, tras el preprocesamiento, un vocabulario de 1.690 términos. LDA con 3 temas y los bigramas resumen de qué se habla; no se muestran nombres de autores.

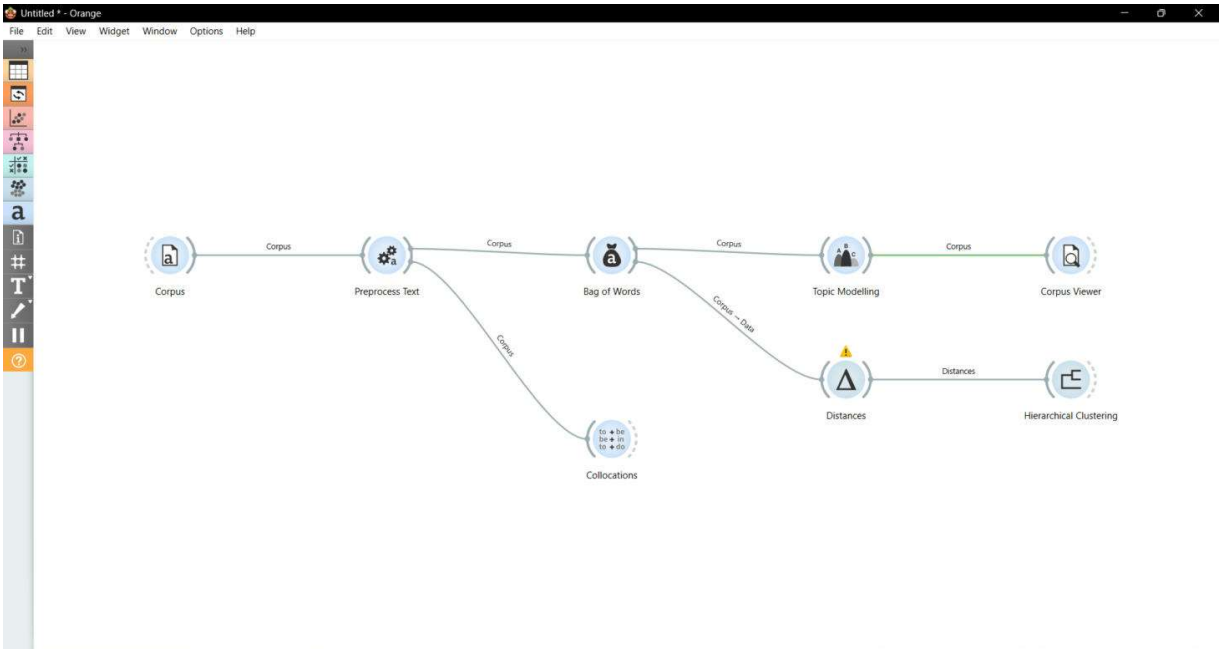


Figura 30. *Lienzo del flujo 03_comentarios_youtube.ows.*

Corpus. Carga `data\processed\etapa6\comentarios_limpios.tab`. Campo de texto `texto`, idioma Spanish; `id_hash`, `video_id` y `fecha` quedan como texto ignorado.

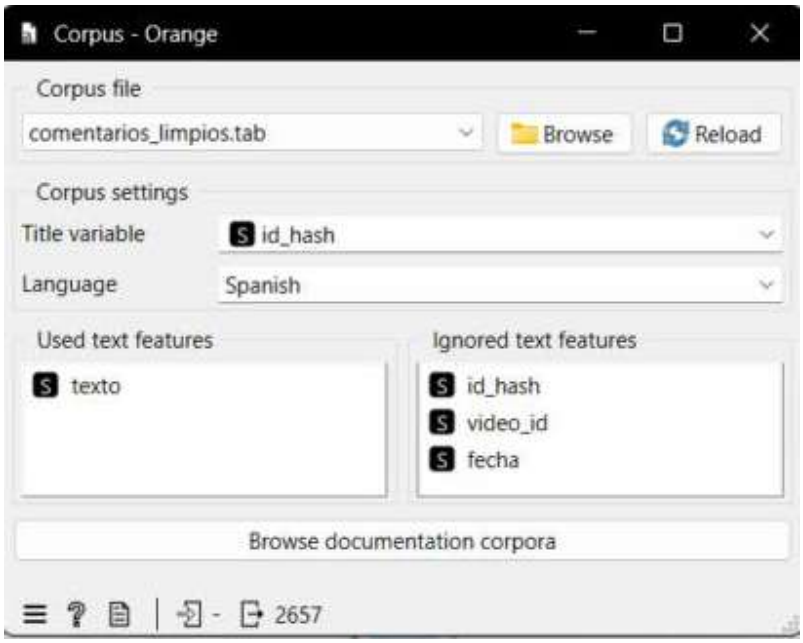


Figura 31. *Widget Corpus.*

Preprocess Text. Cuatro pasos en este orden:

1. Transformation: Lowercase, Remove accents y Remove urls.

2. Tokenization: Regexp `\w+`.

3. Normalization: Snowball Stemmer, idioma Spanish.

4. Filtering: Stopwords desde el archivo `etapa6_stopwords_es.txt` (idioma «none»), Numbers y Document frequency absoluta, mínimo 3 y máximo 100.000.

Salida: 29.221 tokens y 1.690 tipos.

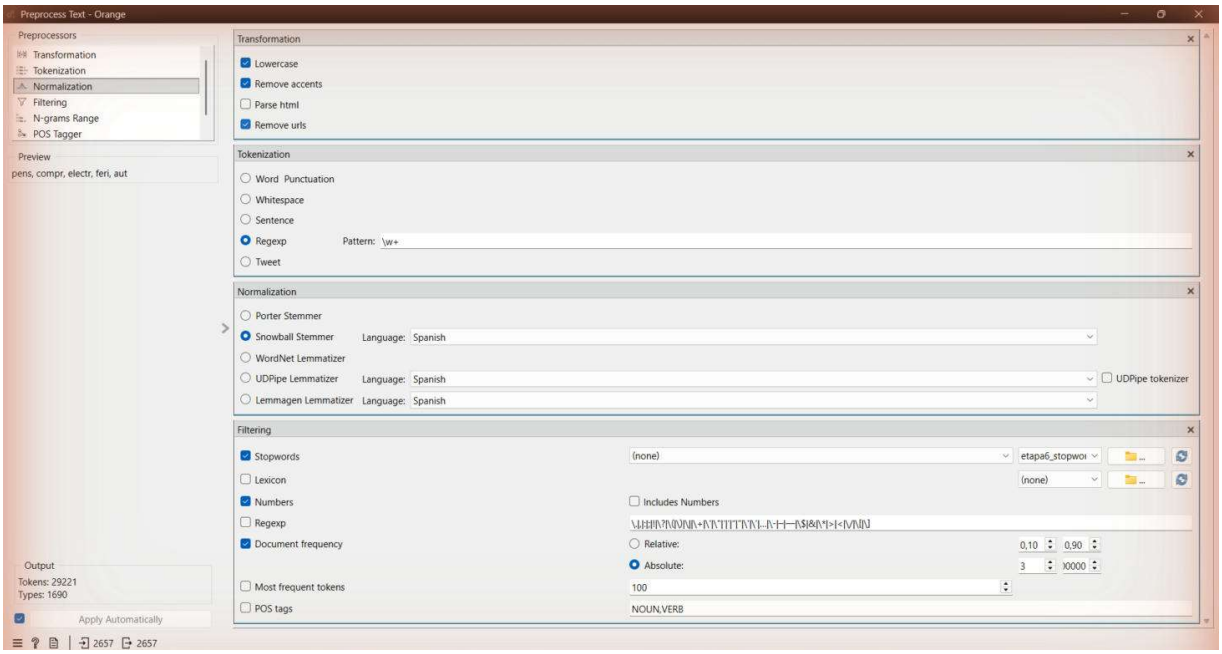


Figura 32. *Preprocess Text con sus cuatro pasos.*

Bag of Words. Term frequency Count, Document frequency IDF, Regularization L2 (Euclidean).

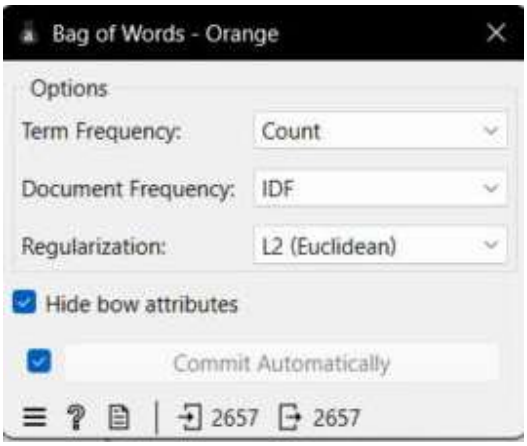


Figura 33. *Widget Bag of Words.*

Distances → Hierarchical Clustering. Desde Bag of Words con distancia Cosine, para ver agrupaciones de comentarios.

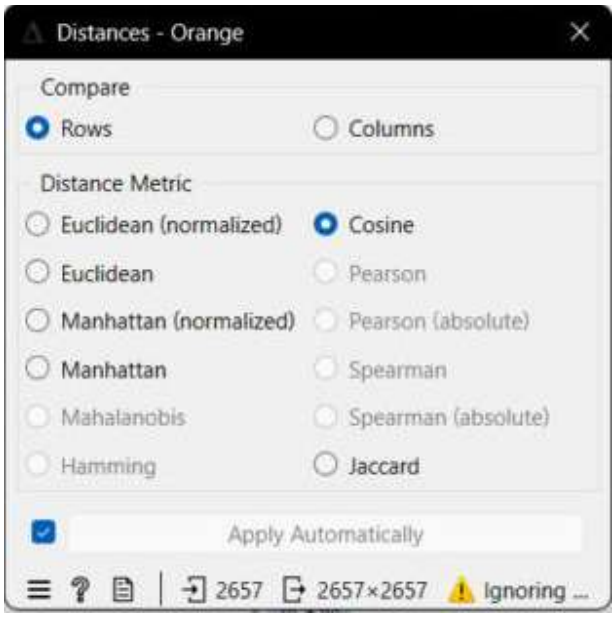


Figura 34. *Widget Distances (coseno).*

Topic Modelling. Método LDA con 3 temas (coherencia 0,40 según el widget; el script, con la medida c_v, obtiene 0,48 para k = 3: son cálculos distintos y no se comparan). Los temas obtenidos:

Tema	Palabras principales (en raíz)	Lectura
1	carg, hibr, compr, preci, electr, gasolin	Precio y compra: eléctrico, híbrido o gasolina
2	carr, plac, pic, repuest, chin, deepal	Carros, pico y placa, repuestos y marcas chinas
3	inform, bateri, cargador, cost, colombi	Baterías, cargadores y costos en Colombia

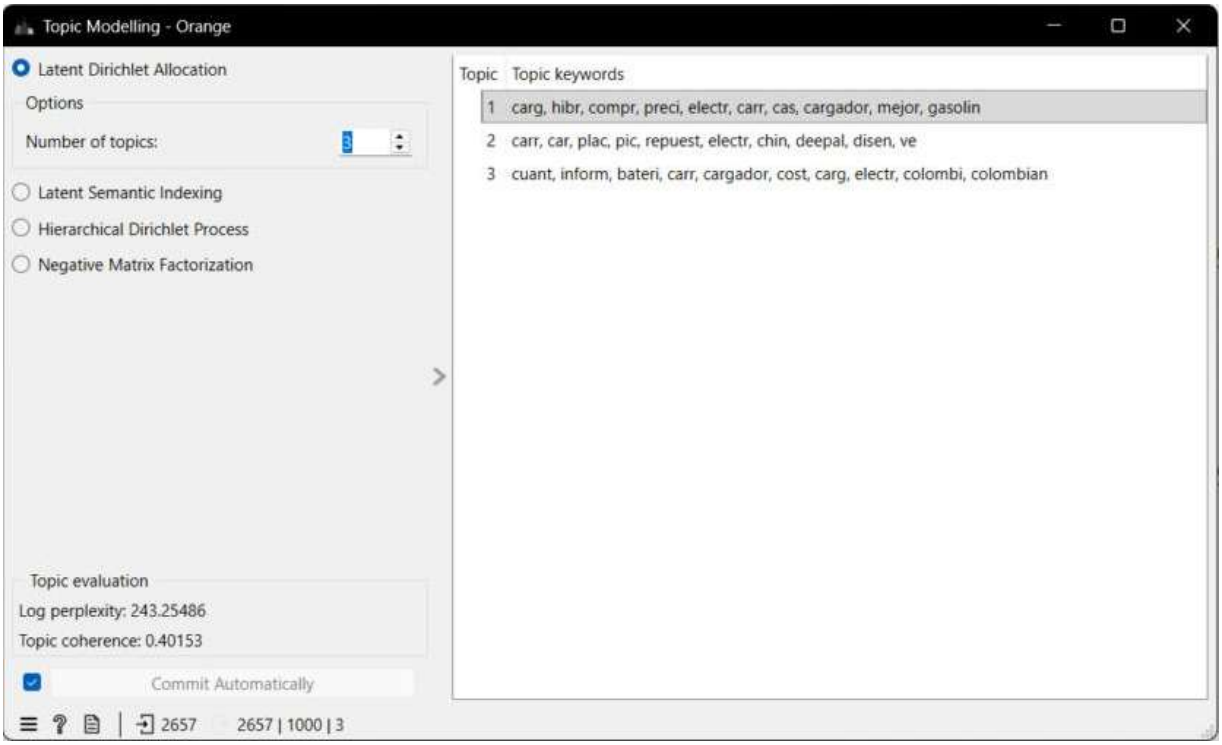


Figura 35. *Topic Modelling con las palabras de cada tema.*

Collocations. Desde Preprocess Text, bigramas con puntuación Raw Frequency. Los más frecuentes: carr electr, vehicul electr, aut electr, compr carr, pic plac, medi ambient y vid util.

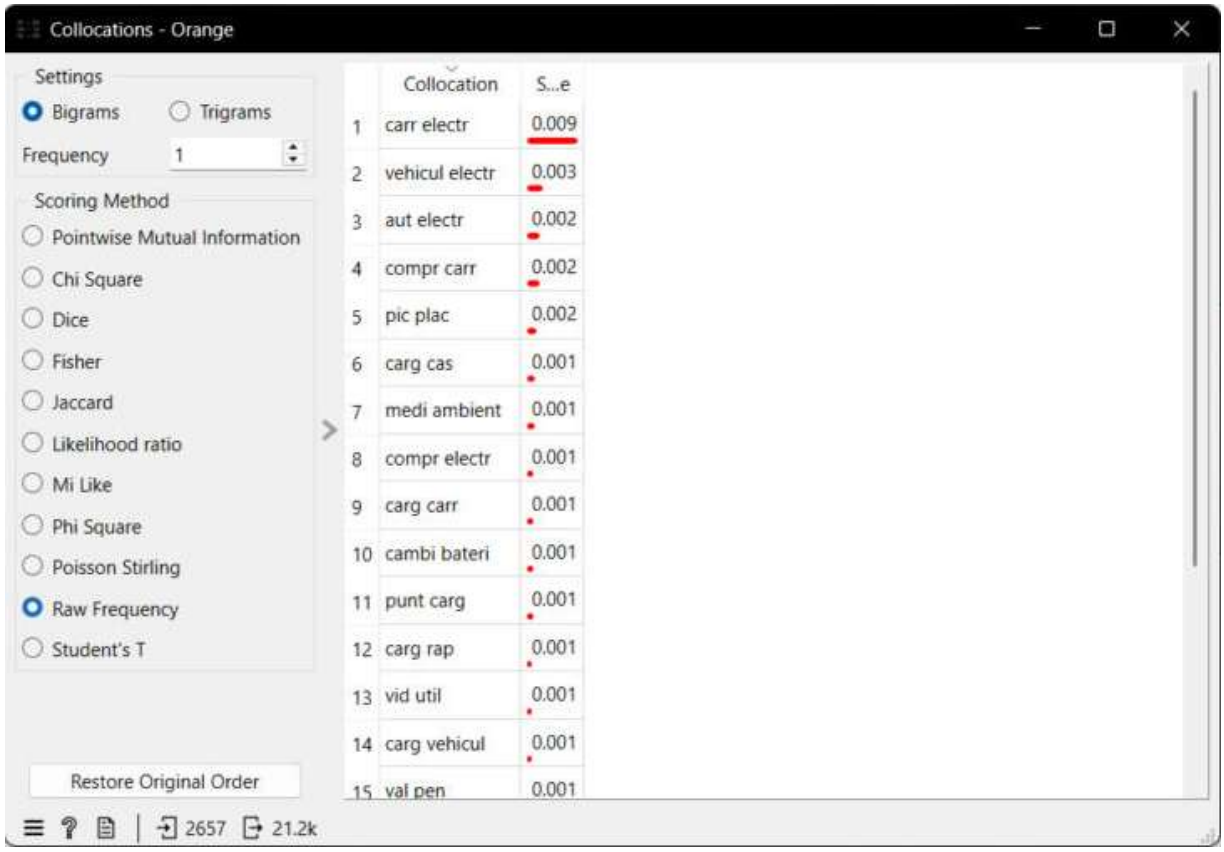


Figura 36. *Collocations (bigramas más frecuentes).*

Cifras obtenidas frente a las esperadas

Las cifras esperadas son las de los scripts del repositorio (resultados_etapa6_*.json). De 15 comprobaciones, 12 coinciden exactamente o dentro de la tolerancia; las otras tres (silueta de k = 4 y k = 5, bigramas y temas LDA) difieren levemente o se expresan distinto, como se explica en las observaciones.

Comprobación	Esperado	Obtenido	Estado
Filas tras quitar hidrógeno	6.768	6.768	✓
ELECTRICO / HIBRIDO	3.583 / 3.185	3.583 / 3.185	✓
Rank: carrocería / clase	0,554 / 0,468	0,554 / 0,468	✓
Regresión logística (AUC, CA)	0,941 / 0,870	0,941 / 0,870	✓
Random Forest (Prec. /	0,914 / 0,829	0,916 / 0,827	✓

Comprobación	Esperado	Obtenido	Estado
Recall)			(±0,002)
Árbol (AUC / Prec.)	0,904 / 0,872	0,904 / 0,871	✓
Matriz de confusión	2.875 / 708 / 170 / 3.015	2.875 / 708 / 170 / 3.015	✓
Territorios agrupados	247	247	✓
Territorios con ≥ 30 vehículos	98	98	✓
Silueta k = 2, 3, 6, 7, 8	0,452 / 0,286 / 0,249 / 0,255 / 0,262	Iguales	✓
Silueta k = 4 y k = 5	0,239 / 0,266	0,244 / 0,264	✗ leve
Tamaños con k = 3	22 / 34 / 42	22 / 34 / 42	✓
Comentarios y vocabulario	2.657 / ≈ 1.690	2.657 / 1.690	✓
Bigramas principales	carro eléctrico (≈ 139), carros eléctricos (≈ 118)…	carr electr, vehicul electr, pic plac…	≈ (en raíz)
Temas LDA	Baterías y carga; precio y compra; carga en casa	Precio y compra; pico y placa y repuestos; baterías y costos	≈

Observaciones:

- Las diferencias en k = 4 y k = 5 (0,005 y 0,002) son leves y no cambian la elección de k = 3. El widget k-Means usa semilla fija, así que no se trata de azar; la causa exacta no se determinó.
- Los bigramas salen en raíz porque se aplica stemming antes de Collocations: «carr electr» junta «carro eléctrico» y «carros eléctricos», así que su frecuencia no se compara directamente con la del script etapa6_youtube_analisis.py, que cuenta las palabras completas.
- LDA tiene azar: los temas se parecen a los esperados, pero no son idénticos, y no se midió el porcentaje de comentarios por tema.

Recursos

Recurso	URL
Conjunto de datos	datos.gov.co · ntxy-q9ix
Repositorio	github.com/Lando18tinez/MINERIA_AJ
Aplicación publicada	mineria-aj.onrender.com